LAPORAN PORTOFOLIO ASESMEN SERTIFIKASI DATA SCIENCE

Analisis Pengelompokan Negara Berdasarkan Profil Demografi Dunia

Unsupervised K-Means Clustering · 234 Negara & Teritori
Metodologi CRISP-DM terintegrasi 9 Unit Kompetensi SKKNI

PENELITI UTAMA & PENGEMBANG MODEL

M. IQBAL ADENAN

Lead Data Scientist & Developer · Asesi Okupasi Associate Data Scientist

Skema Okupasi	Associate Data Scientist (KKNI Level 5 / Okupasi 010601)
Nomor Skema	SSK22/BPPMPVKPTK/KKRPL/2022
Standar	SKKNI Nomor 299 Tahun 2020 (9 Unit Kompetensi)
Institusi Acuan	Kementerian Komunikasi dan Digital RI (KOMDIGI) / BPPMPV KPTK

LIHAT HASIL PENGEMBANGAN (DASHBOARD INTERAKTIF)

https://10040818.github.io/associate_data_scientist_world_demographic_clustering/

Dataset uji: World Population Dataset (234 negara & teritori, 17 variabel) · Oktober 2026

Lembar Identitas Laporan

Judul Laporan	Analisis Pengelompokan Negara Berdasarkan Profil Demografi Dunia Menggunakan Algoritma Unsupervised K-Means Clustering
Nama Asesi / Peneliti	**M. IQBAL ADENAN** (Muhammad Iqbal Adenan)
Peran	Peneliti Utama & Pengembang Model (Lead Data Scientist & Developer)
Skema Okupasi	Associate Data Scientist, KKNI Level 5 / Okupasi 010601
Nomor Skema Asesmen	SSK22/BPPMPVKPTK/KKRPL/2022
Standar Kompetensi	SKKNI Nomor 299 Tahun 2020, terdiri dari 9 Unit Kompetensi
Institusi Acuan	Kementerian Komunikasi dan Digital RI (KOMDIGI) / BPPMPV KPTK
Dataset Uji	World Population Dataset: 234 negara & teritori, 17 variabel demografi
Metodologi	CRISP-DM yang dipetakan ke 9 Unit Kompetensi SKKNI
Hasil Pengembangan	Dashboard interaktif: https://10040818.github.io/associate_data_scientist_world_demographic_clustering/

Cara membaca laporan ini

Setiap bab mengikuti satu unit kompetensi SKKNI dan disusun dengan pola yang sama: **tujuan** unit, **kode Python** yang dipakai pada tahap itu, **penjelasan cara kerja kode**, lalu **hasil dan interpretasi**. Kode tidak dikumpulkan di lampiran; ia ditempatkan tepat di subbab yang menggunakannya, dengan penomoran Kode `X.Y` yang sama dengan nomor bab. Setiap potongan kode hanya muncul satu kali. Variabel yang dibuat pada satu kode (misalnya `df`, `X_scaled`, `K_OPTIMAL`) dipakai ulang oleh kode berikutnya tanpa ditulis ulang, sehingga seluruh kode dapat dijalankan berurutan dari atas ke bawah.

Tiga penanda kode

Kotak biru tua berlabel **KODE** adalah kode dari notebook analisis (`analisis_kmeans.ipynb`) yang diringkas tanpa mengubah logikanya.

Label **PELENGKAP** menandai kode tambahan untuk grafik atau pembuktian yang ada di laporan tetapi belum ada sel pembuatnya di notebook (Gambar 4, Gambar 10, dan uji angka 0,00%).

Baris yang diawali # adalah komentar penjelas.

Daftar Isi

Pendahuluan 5

Latar Belakang Proyek 5

Tujuan dan Sasaran Operasional 5

Peta Unit Kompetensi, Fase CRISP-DM, dan Kode yang Digunakan 5

Bab 1 · Mengumpulkan Data 7

1.1 Identifikasi Sumber dan Ukuran Data 7

1.2 Paradigma Pembelajaran: Unsupervised Learning 7

1.3 Penyiapan Pustaka 7

1.4 Pemuatan Dataset ke DataFrame 7

Bab 2 · Menelaah Data 9

2.1 Dimensi, Sampel, Kolom, Struktur Memori, dan Tipe Data 9

2.2 Statistik Deskriptif dan Sebaran Benua 10

Bab 3 · Memvalidasi Data 12

3.1 Validasi Kelengkapan dan Keunikan Data 12

3.2 Validasi Integritas Atribut Khusus: Angka 0,00% 12

Bab 4 · Menentukan Objek Data 14

4.1 Identifikasi Objek Observasi 14

4.2 Bentuk Distribusi dan Skewness Mentah 14

4.3 Uji Multikolinearitas Antarvariabel 15

4.4 Seleksi Empat Pilar Fitur Demografi Kunci 17

Bab 5 · Membersihkan Data 20

5.1 Filosofi Penanganan Outlier: Zero Data Loss 20

5.2 Transformasi Logaritma Natural (np.log1p) 20

5.3 Evaluasi Penurunan Skewness dan Normalisasi Sebaran 20

Bab 6 · Mengkonstruksi Data 22

6.1 Standardisasi Skala Z-Score (StandardScaler) 22

6.2 Validasi Fitur Terstandarisasi 22

Bab 7 · Menentukan Label Data 24

7.1 Elbow Method: Inersia WCSS 24

7.2 Silhouette Score: Kohesi dan Separasi Klaster 25

7.3 Keputusan Final: K = 4 26

7.4 Taksonomi Label Resmi (Business Labeling) 27

Bab 8 · Membangun Model 29

8.1 Konfigurasi dan Pelatihan K-Means++ 29

8.2 Ekstraksi Titik Pusat Massa (Centroid) 29

8.3 Serialisasi Model dan Pipeline (Joblib) 30

Bab 9 · Mengevaluasi Hasil Pemodelan 32

9.1 Sebaran Klaster dan Centroid pada Ruang Z-Score 32

9.2 Distribusi Jumlah Negara per Klaster 33

9.3 Komposisi Geografis Benua per Klaster 34

9.4 Validasi Multidimensi: Pairplot Klaster 35

9.5 Profiling Karakteristik Statistik Empat Klaster 37

9.6 Ekspor Dataset Terklaster dan Inventaris Arsip Grafik 38

9.7 Deployment Dashboard Web Interaktif 39

9.8 Kesimpulan Eksekutif dan Rekomendasi Kebijakan 39

PENDAHULUAN

Tujuan dan Latar Belakang Proyek

Kode unit: `Ringkasan proyek`

Latar Belakang Proyek

Dinamika kependudukan global ditandai ketimpangan spasial yang sangat tajam. Menurut Divisi Kependudukan Perserikatan Bangsa-Bangsa (UN DESA), populasi bumi pada tahun 2022 menembus 7,97 miliar jiwa dan terdistribusi sangat tidak merata. Di satu sisi terdapat negara raksasa seperti China dan India, masing-masing dengan lebih dari 1,4 miliar penduduk, yang menuntut pasokan energi, ketahanan pangan, dan mitigasi emisi karbon berskala masif. Di sisi lain terdapat negara kepulauan dan teritori mikro dengan daratan sangat sempit tetapi kepadatan ekstrem (Macau, Monako, Singapura) yang rentan terhadap tekanan ekologis dan kenaikan permukaan air laut.

Sebagian besar kawasan Afrika dan Asia berkembang mengalami pertumbuhan penduduk usia muda yang cepat (1,5% hingga 3,0% per tahun). Kondisi ini menuntut fasilitas kesehatan ibu dan anak, pendidikan dasar, serta lapangan kerja agar bonus demografi tidak berubah menjadi beban. Sebaliknya, negara kontinental luas seperti Rusia, Kanada, Australia, dan Kazakhstan menguasai jutaan kilometer persegi dengan kepadatan sangat rendah, sehingga biaya infrastruktur transportasi dan logistik antarkota menjadi tantangan utama.

Pengelompokan negara yang lazim digunakan, yaitu menurut benua atau menurut pendapatan (GDP), sering gagal menggambarkan kesamaan tantangan demografi yang sebenarnya. Benua Asia, misalnya, memuat negara kota super padat (Singapura), raksasa demografi (China, India), sekaligus negara stepa yang renggang (Mongolia). Menyamaratakan kebijakan berdasarkan batas benua tidak efektif. Penelitian ini karenanya memakai algoritma *Unsupervised K-Means Clustering* untuk membagi 234 negara dan teritori berdasarkan pola data multivariat, tanpa campur tangan penilaian subjektif.

Tujuan dan Sasaran Operasional

1. **Segmentasi alami yang objektif.** Mengelompokkan 234 negara dan teritori ke dalam klaster homogen berdasarkan empat pilar demografi: ukuran populasi, luas daratan, kepadatan, dan laju pertumbuhan tahunan.
2. **Identifikasi pola ketimpangan spasial.** Mendeteksi polarisasi populasi dunia dan menempatkan negara ekstrem (megapopulasi dan mikro padat) pada ruang koordinat demografi global.
3. **Evaluasi metodologis dan rekayasa fitur.** Membuktikan secara empiris multikolinearitas sempurna (r = 1,00) antarkolom populasi historis 1970 hingga 2022, lalu mengeliminasi redundansi itu agar jarak Euclidean K-Means tidak terdistorsi.
4. **Rekomendasi kebijakan.** Menghasilkan bukti berbasis data bagi badan internasional (PBB, Bank Dunia, WHO), perencana kebijakan nasional, dan investor global.

Peta Unit Kompetensi, Fase CRISP-DM, dan Kode yang Digunakan

Tabel berikut adalah daftar isi teknis laporan. Kolom *Kode* menunjukkan nomor kode Python yang dipakai pada bab tersebut sehingga pembaca dapat langsung menemukan kode untuk setiap unit.

No.	Unit kompetensi (kode unit)	Fase CRISP-DM	Kode yang digunakan	Keluaran utama
1	Mengumpulkan Data (J.62DMI00.004.1)	Business & Data Understanding	1.1 impor pustaka 1.2 muat dataset	DataFrame `df` 234×17
2	Menelaah Data (J.62DMI00.005.1)	Data Understanding	2.1 struktur & tipe 2.2 statistik & benua	Kamus data, statistik deskriptif
3	Memvalidasi Data (J.62DMI00.006.1)	Data Understanding	3.1 missing & duplikat 3.2 uji 0,00% (pelengkap)	0 missing, 0 duplikat
4	Menentukan Objek Data (J.62DMI00.007.1)	Data Understanding	4.1 skewness 4.2 korelasi 4.3 fitur kunci 4.4 pairplot (pelengkap)	4 fitur terpilih, Gambar 1 s.d. 4
5	Membersihkan Data (J.62DMI00.008.1)	Data Preparation	5.1 log1p 5.2 visual sebelum-sesudah	`df_log`, Gambar 5
6	Mengkonstruksi Data (J.62DMI00.009.1)	Data Preparation	6.1 StandardScaler 6.2 visual terstandarisasi	`X_scaled`, Gambar 6
7	Menentukan Label Data (J.62DMI00.010.1)	Modeling (pemilihan K)	7.1 s.d. 7.5 Elbow, Silhouette, keputusan K 7.6 label & nama klaster	K = 4, Gambar 7 s.d. 9
8	Membangun Model (J.62DMI00.013.1)	Modeling	8.1 pelatihan 8.2 centroid 8.3 heatmap (pelengkap) 8.4 serialisasi	`model_kmeans.pkl`, `scaler.pkl`
9	Mengevaluasi Hasil Pemodelan (J.62DMI00.014.1)	Evaluation & Deployment	9.1 s.d. 9.5 visualisasi 9.6 profiling 9.7 ekspor & inventaris	Profil klaster, CSV, dashboard web

Urutan eksekusi

Kode dijalankan berurutan sesuai nomor. Satu pengecualian disebutkan eksplisit pada Bab 7: pelabelan klaster (Kode 7.6) membutuhkan model yang dilatih pada Kode 8.1, sehingga di notebook kedua blok itu dijalankan berdampingan: Kode 8.1 lebih dulu, baru 7.6.

BAB 1 · UNIT KOMPETENSI 1

Mengumpulkan Data

Kode unit: `J.62DMI00.004.1`

Unit ini mencakup identifikasi sumber data, penegasan paradigma pembelajaran mesin, penyiapan perangkat komputasi, dan pemuatan data ke memori kerja. Tahap ini menjamin bahwa seluruh analisis berikutnya bertumpu pada data yang sah, lengkap, dan dapat ditelusuri asalnya.

1.1 Identifikasi Sumber dan Ukuran Data

Data berasal dari dataset publik *World Population Dataset* di platform Kaggle (kaggle.com/datasets/iamsouravbanerjee/world-population-dataset). Dataset ini menghimpun data sensus resmi dan estimasi kependudukan dunia dari Divisi Kependudukan PBB (UN DESA). Ukurannya 234 baris dan 17 kolom; setiap baris adalah satu negara berdaulat atau satu wilayah teritori resmi.

1.2 Paradigma Pembelajaran: Unsupervised Learning

Penelitian ini memakai pembelajaran mesin tak terawasi. Dua konsekuensinya penting untuk dipahami sebelum membaca bab-bab berikutnya:

- **Tidak ada variabel target (y).** Tidak ada kolom yang ingin ditebak nilainya. K-Means bukan alat prediksi masa depan seperti regresi atau klasifikasi berlabel; ia mencari struktur kemiripan alami antartitik data pada ruang multidimensi tanpa label kelas sebelumnya.
- **Tidak ada pembagian data latih dan uji.** Pola 80:20 atau 70:30 tidak dipakai. Jika data dibagi 80:20, hanya sekitar 187 negara yang terkelompok dan 47 negara lain tertinggal tanpa label. Karena tujuannya memetakan seluruh dunia, seluruh 234 negara (100% data sensus) diproses utuh.

1.3 Penyiapan Pustaka

Lingkungan analisis memakai Python 3 dengan pustaka standar industri sains data. Kode 1.1 mengimpor enam modul yang dipakai sepanjang laporan. Pustaka `scikit-learn` dan `joblib` sengaja tidak diimpor di sini; keduanya diimpor tepat pada tahap yang membutuhkannya (Bab 6, 7, dan 8) agar jelas tahap mana yang bergantung pada pustaka itu.

KODE 1.1 Impor pustaka utama

```
import numpy as np                    # komputasi numerik: log1p / expm1
import pandas as pd                   # DataFrame, groupby, crosstab
import matplotlib.pyplot as plt       # kanvas dan penyimpanan grafik
import seaborn as sns                 # grafik statistik: histplot, boxplot, pairplot
from pathlib import Path              # jalur berkas yang aman lintas sistem operasi
from IPython.display import display   # menampilkan tabel HTML di notebook
```

1.4 Pemuatan Dataset ke DataFrame

Kode 1.2 menetapkan direktori kerja secara dinamis, membuat folder `output/` bila belum ada, lalu membaca berkas CSV ke DataFrame `df`.

KODE 1.2 **Inisialisasi direktori dan pemuatan dataset**

```
BASE_DIR   = Path.cwd()                                    # direktori kerja aktif
DATA_PATH  = BASE_DIR / 'dataset' / 'world_population.csv'  # berkas masukan
OUTPUT_DIR = BASE_DIR / 'output'                           # tempat grafik, CSV, model
OUTPUT_DIR.mkdir(parents=True, exist_ok=True)              # dibuat otomatis jika belum ada

df = pd.read_csv(DATA_PATH)            # seluruh isi CSV masuk ke memori sebagai DataFrame
sns.set_theme(style='whitegrid')       # tema seragam agar semua grafik konsisten
print(f'Dimensi dataset: {df.shape[0]} baris x {df.shape[1]} kolom')
```

- `Path.cwd()` dan operator `/` membangun jalur berkas dinamis sehingga kode jalan di Windows, Linux, maupun macOS.
- `mkdir(parents=True, exist_ok=True)` aman dijalankan berulang kali; tidak error bila folder sudah ada.
- `sns.set_theme(style='whitegrid')` dipanggil sekali di sini dan berlaku untuk semua grafik berikutnya.

Hasil Bab 1

Dataset termuat utuh ke memori kerja: **234 baris × 17 kolom**, tanpa kerusakan berkas. Dimensi ini diverifikasi ulang secara eksplisit pada Kode 2.1.

BAB 2 · UNIT KOMPETENSI 2

Menelaah Data

Kode unit: J.62DMI00.005.1

Unit ini menelaah struktur internal dataset: dimensi, nama kolom, tipe data, kamus variabel, dan ringkasan statistik. Tujuannya memahami data sebelum diubah, sehingga setiap keputusan pra-pemrosesan di bab selanjutnya punya dasar yang terlihat.

2.1 Dimensi, Sampel, Kolom, Struktur Memori, dan Tipe Data

Kode 2.1 memeriksa data dari yang paling umum hingga yang paling rinci. `df.shape` mengonfirmasi dimensi; `df.head()` menampilkan lima baris pertama untuk memeriksa nama kolom dan format nilai; daftar kolom bernomor menjadi dasar kamus data; `df.info()` melaporkan jumlah nilai non-null, tipe, dan penggunaan memori; `df.dtypes` memisahkan kolom teks dari kolom numerik.

KODE 2.1 Dimensi, sampel, nama kolom, struktur teknis, dan tipe data

```
print(df.shape)                          # (jumlah baris, jumlah kolom) -> (234, 17)
display(df.head(5))                      # lima negara pertama: cek nama kolom dan format nilai

for nomor, nama_kolom in enumerate(df.columns, start=1):    # daftar 17 kolom bernomor
    print(f'Kolom [{nomor:02d}] : {nama_kolom}')

df.info()                                # non-null per kolom, tipe data, estimasi memori
print(df.dtypes)                         # object (teks), int64 (bulat), float64 (desimal)
```

Hasil. Seluruh 17 kolom memiliki 234 nilai non-null, dan dataset hanya membutuhkan memori sekitar 31 KB. Pemeriksaan tipe data memisahkan kolom menjadi tiga kelompok:

Tipe	Jumlah	Kolom
object (teks)	4	CCA3 (kode ISO 3 huruf), Country/Territory, Capital, Continent
int64 (bilangan bulat)	10	Rank, Area (km²), dan delapan kolom populasi (2022, 2020, 2015, 2010, 2000, 1990, 1980, 1970)
float64 (desimal)	3	Density (per km²), Growth Rate, World Population Percentage

Kamus data: definisi operasional 17 variabel

Variabel	Definisi operasional
Country/Territory	Nama resmi negara atau wilayah teritori berdaulat.
CCA3	Kode unik 3 huruf standar ISO 3166-1 alpha-3 (IDN, USA, CHN, dan seterusnya).
Capital	Pusat pemerintahan atau ibu kota resmi.
Continent	Benua geografis: Asia, Africa, Europe, North America, South America, Oceania.
2022 Population	Estimasi jumlah penduduk resmi tahun 2022 (jiwa).
2020, 2015, 2010, 2000, 1990, 1980, 1970 Population	Catatan historis jumlah penduduk pada tahun tersebut (jiwa).
Area (km²)	Luas total daratan kedaulatan dalam kilometer persegi.
Density (per km²)	Kepadatan penduduk per km² (populasi dibagi luas).
Growth Rate	Faktor laju pertumbuhan tahunan; 1,0150 berarti tumbuh 1,50% per tahun.
World Population Percentage	Persentase kontribusi penduduk negara terhadap total populasi bumi.
Rank	Peringkat populasi global dari 1 (terbesar) hingga 234 (terkecil).

2.2 Statistik Deskriptif dan Sebaran Benua

Kode 2.2 menghitung delapan metrik ringkasan untuk setiap kolom numerik (`count, mean, std, min, 25%, 50%, 75%, max`) dan memeriksa kategori benua beserta jumlah negara di tiap benua. Informasi benua dipakai kembali pada Bab 9 untuk tabulasi silang dengan klaster.

KODE 2.2 Statistik deskriptif dan distribusi benua

```
display(df.describe())                      # ringkasan 8 metrik untuk semua kolom numerik

print('Jumlah benua unik :', df['Continent'].nunique())
print(df['Continent'].value_counts())       # jumlah negara per benua (urut menurun)
```

Statistik	2022 Population	Area (km²)	Density (per km²)	Growth Rate	World Pop %
count	234	234	234	234	234
mean	34.074.414	581.449	452,13	1,00957	0,427%
std	136.766.424	1.761.840	2.078,37	0,01338	1,714%
min	510	1	0,026	0,91200	0,00%
25% (Q1)	415.284	2.650	36,598	1,00177	0,01%
50% (median)	5.559.944	71.741	95,346	1,00790	0,07%
75% (Q3)	24.292.729	418.317	216,890	1,01695	0,30%
max	1.425.887.337	17.098.242	23.172,26	1,06910	17,88%

Cara membaca statistik deskriptif

1. Jurang mean dan median. Rata-rata populasi dunia 34 juta jiwa, tetapi mediannya hanya 5,5 juta. Rata-rata terkatrol sekitar enam kali lipat oleh dua raksasa (China dan India, lebih dari 1,4 miliar). Ini tanda ilmiah bahwa data menceng tajam ke kanan.

2. Simpangan baku melebihi rata-rata. Simpangan baku populasi (136 juta) jauh di atas rata-ratanya (34 juta): disparitas ukuran negara sangat ekstrem.

3. Kontras min dan max. Populasi terkecil 510 jiwa (Vatikan) berbanding terbesar 1,425 miliar (China), selisih sekitar 2,8 juta kali. Kepadatan terendah 0,026 jiwa/km² (Greenland) berbanding tertinggi 23.172 jiwa/km² (Monako), selisih hampir 1 juta kali.

Implikasi. Rentang skala yang sangat lebar antarvariabel (populasi miliaran, luas jutaan km², pertumbuhan sekitar 1,0) adalah alasan utama perlunya transformasi logaritma (Bab 5) dan standardisasi (Bab 6) sebelum K-Means dijalankan.

BAB 3 · UNIT KOMPETENSI 3

Memvalidasi Data

Kode unit: `J.62DMI00.006.1`

Unit ini menguji keabsahan data sebelum dianalisis: kelengkapan (nilai kosong), keunikan (duplikasi), dan integritas atribut khusus. K-Means tidak dapat menerima nilai kosong, dan baris ganda akan membuat satu negara dihitung dua kali sehingga menggeser posisi centroid. Karena itu validasi dilakukan sebelum tahap apa pun yang mengubah data.

3.1 Validasi Kelengkapan dan Keunikan Data

`df.isnull()` menghasilkan matriks boolean (True bila sel kosong); `.sum()` menjumlahkannya per kolom. `df.duplicated()` menandai baris yang identik dengan baris sebelumnya. Nilai 0 pada keduanya berarti data bersih tanpa perlu imputasi.

KODE 3.1 Uji nilai hilang dan duplikasi baris

```
missing_per_col = df.isnull().sum()                # jumlah sel kosong tiap kolom
print(missing_per_col)
total_missing = missing_per_col.sum()
if total_missing == 0:
    print('STATUS: Data bersih! Tidak ditemukan missing value (100% lengkap).')
else:
    print(f'PERINGATAN: Ditemukan {total_missing} missing value yang perlu ditangani!')

jumlah_duplikat = df.duplicated().sum()            # baris yang kembar dengan baris sebelumnya
print(f'Jumlah baris duplikat : {jumlah_duplikat} baris')
```

Uji	Hasil	Kesimpulan
Missing values (17 kolom)	0	Data 100% lengkap dan utuh.
Baris duplikat	0	Setiap baris adalah satu negara atau wilayah yang unik.
Imputasi mean atau median	Tidak dilakukan	Seluruh data diproses murni dan orisinal, tanpa nilai buatan.

3.2 Validasi Integritas Atribut Khusus: Angka 0,00%

Pada kolom *World Population Percentage*, 57 negara tercatat bernilai 0,00%. Bagi pembaca awam ini tampak seperti data hilang atau kesalahan sistem. Validasi matematis menunjukkan data ini **sah**. Negara-negara tersebut berpopulasi di bawah sekitar 400.000 jiwa. Contohnya Vatikan (510 jiwa): 510 ÷ 7.975.105.156 × 100% = 0,0000064%. Karena kolom hanya menyimpan dua digit desimal, angka sekecil itu dibulatkan menjadi 0,00%.

Kode 3.2 adalah kode pelengkap agar uji ini dapat direproduksi; ia tidak mengubah data.

KODE 3.2 · PELENGKAP **Pembuktian angka 0,00% sebagai pembulatan (bukan data hilang)**

```
pct = df['World Population Percentage']
print('Negara dengan nilai 0.00 :', (pct == 0).sum())                # dilaporkan: 57 negara
print('Populasi terbesar di antara negara itu:', df.loc[pct == 0, '2022 Population'].max())

# bukti pembulatan: porsi Vatikan (510 jiwa) terhadap total populasi bumi, dalam persen
print(510 / df['2022 Population'].sum() * 100)                        # kira-kira 0.0000064
```

Hasil Bab 3

Data lulus validasi: 0 missing value, 0 duplikat, dan angka 0,00% terbukti sebagai efek pembulatan. Tidak diperlukan imputasi apa pun.

BAB 4 · UNIT KOMPETENSI 4

Menentukan Objek Data

Kode unit: J.62DMI00.007.1

Unit ini mengidentifikasi objek observasi, menelaah bentuk sebaran mentah, menguji multikolinearitas, dan memilih fitur kunci. Keputusan penting yang lahir di bab ini adalah: dari 17 kolom, hanya empat fitur yang dipakai untuk klasterisasi.

4.1 Identifikasi Objek Observasi

Objek data adalah 234 entitas negara dan teritori resmi yang terdaftar pada sensus Divisi Kependudukan PBB. Setiap negara adalah satu titik pada ruang fitur, dan K-Means akan mengelompokkan titik-titik itu berdasarkan kedekatannya.

4.2 Bentuk Distribusi dan Skewness Mentah

Skewness (koefisien kemencengan) mengukur kesimetrisan distribusi. Nilai 0 berarti simetris; nilai di atas +1 berarti ekor panjang menjulur ke kanan. Boxplot menandai pencilan sebagai titik di luar batas 1,5 × IQR. Kode 4.1 menghitung skewness keempat fitur kandidat, lalu menggambar histogram berkurva KDE (kiri) dan boxplot (kanan) pada kanvas 4 baris × 2 kolom.

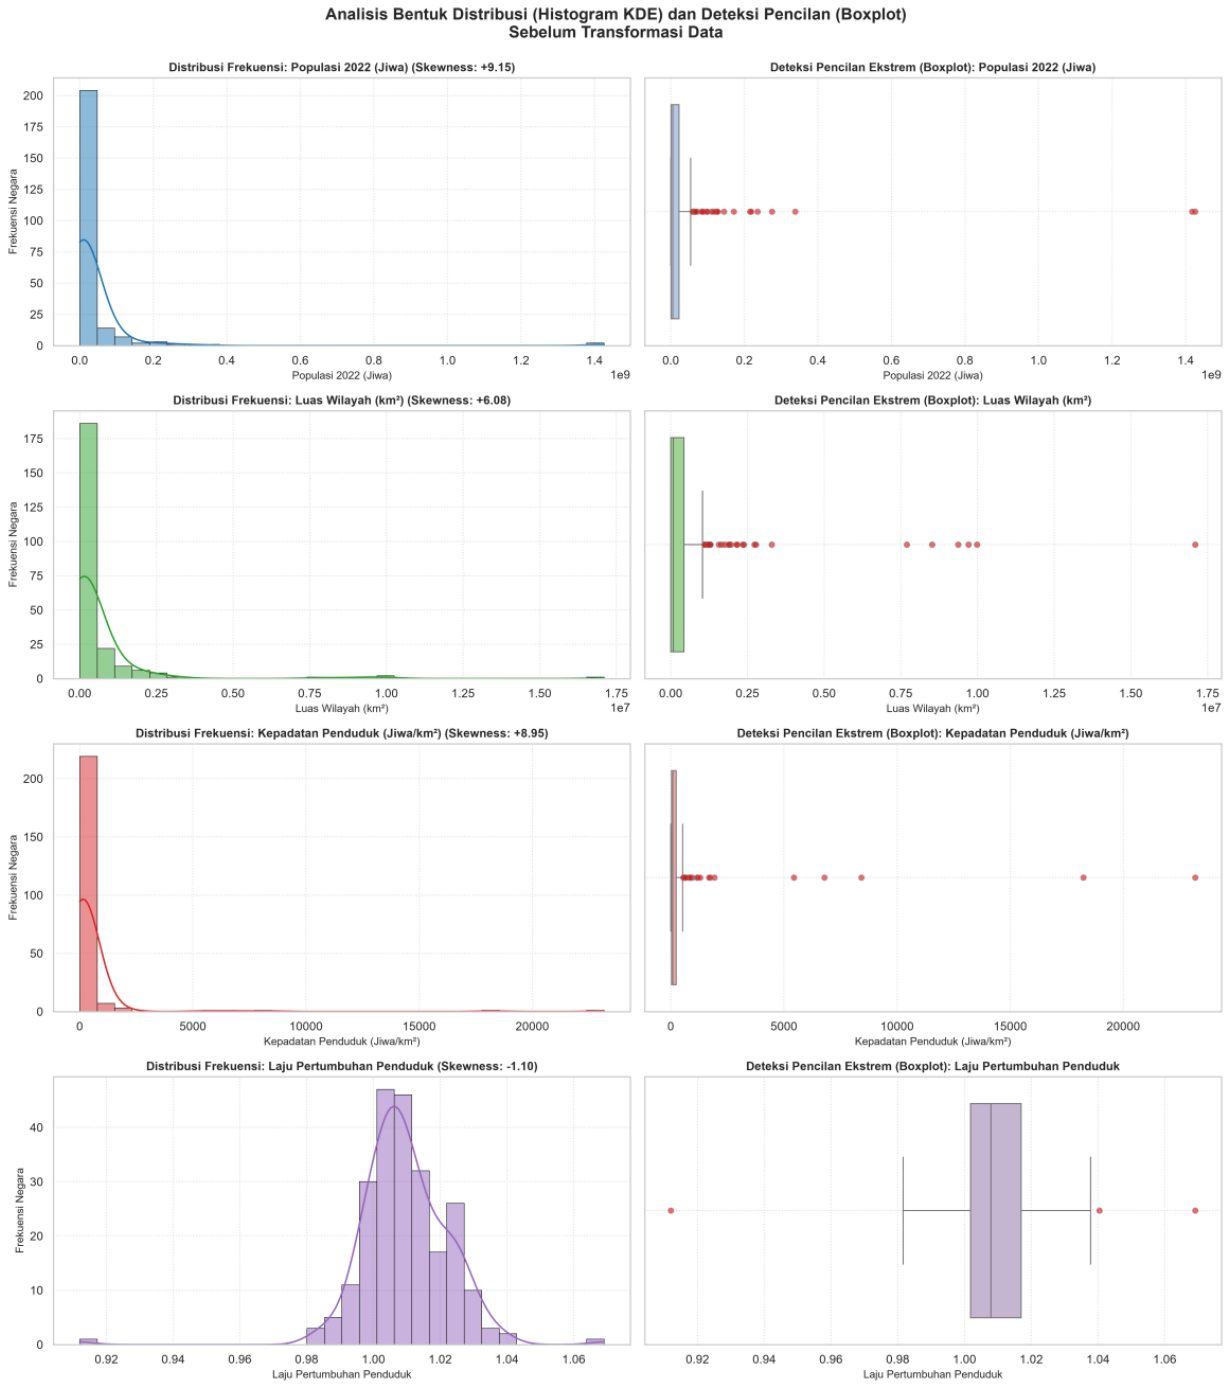
KODE 4.1 Skewness, histogram-KDE, dan boxplot pencilan (Gambar 1)

```
fitur_analisis = ['2022 Population', 'Area (km²)', 'Density (per km²)', 'Growth Rate']
label_fitur = ['Populasi 2022 (Jiwa)', 'Luas Wilayah (km²)',
               'Kepadatan (Jiwa/km²)', 'Laju Pertumbuhan']
warna_hist = ['#1f77b4', '#2ca02c', '#d62728', '#9467bd']
warna_box  = ['#aec7e8', '#98df8a', '#ff9896', '#c5b0d5']

for col in fitur_analisis:                                  # skewness data mentah
    print(f'{col:<20}: skewness = {df[col].skew():+.3f}')

fig, axes = plt.subplots(nrows=4, ncols=2, figsize=(16, 18))
for i, col in enumerate(fitur_analisis):
    sns.histplot(df[col], kde=True, bins=30, ax=axes[i, 0], color=warna_hist[i],
                 edgecolor='black', linewidth=0.5)          # kiri: histogram + kurva KDE
    axes[i, 0].set_title(f'{label_fitur[i]} (Skewness: {df[col].skew():+.2f})')
    sns.boxplot(x=df[col], ax=axes[i, 1], color=warna_box[i],
                flierprops={'marker': 'o', 'markersize': 5, 'markerfacecolor': 'red'})
    axes[i, 1].set_title(f'Deteksi pencilan: {label_fitur[i]}')   # kanan: boxplot
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'eda_distribusi_sebelum_transformasi.png',
            dpi=300, bbox_inches='tight')                   # simpan 300 DPI
plt.show()
```

Hasil. Tiga fitur menceng ekstrem ke kanan: Populasi 2022 **+9,15**, Luas Wilayah **+6,08**, dan Kepadatan **+8,95**. Growth Rate memiliki skewness −1,10 karena segelintir nilai ekstrem di kedua ujungnya, tetapi sebagian besar negara terkonsentrasi di sekitar 1,00. Boxplot memperlihatkan pencilan raksasa (China, India, Rusia) yang menjauh dari mayoritas data.



Gambar 1. Distribusi fitur demografi mentah sebelum transformasi (skewness ekstrem lebih dari +6).

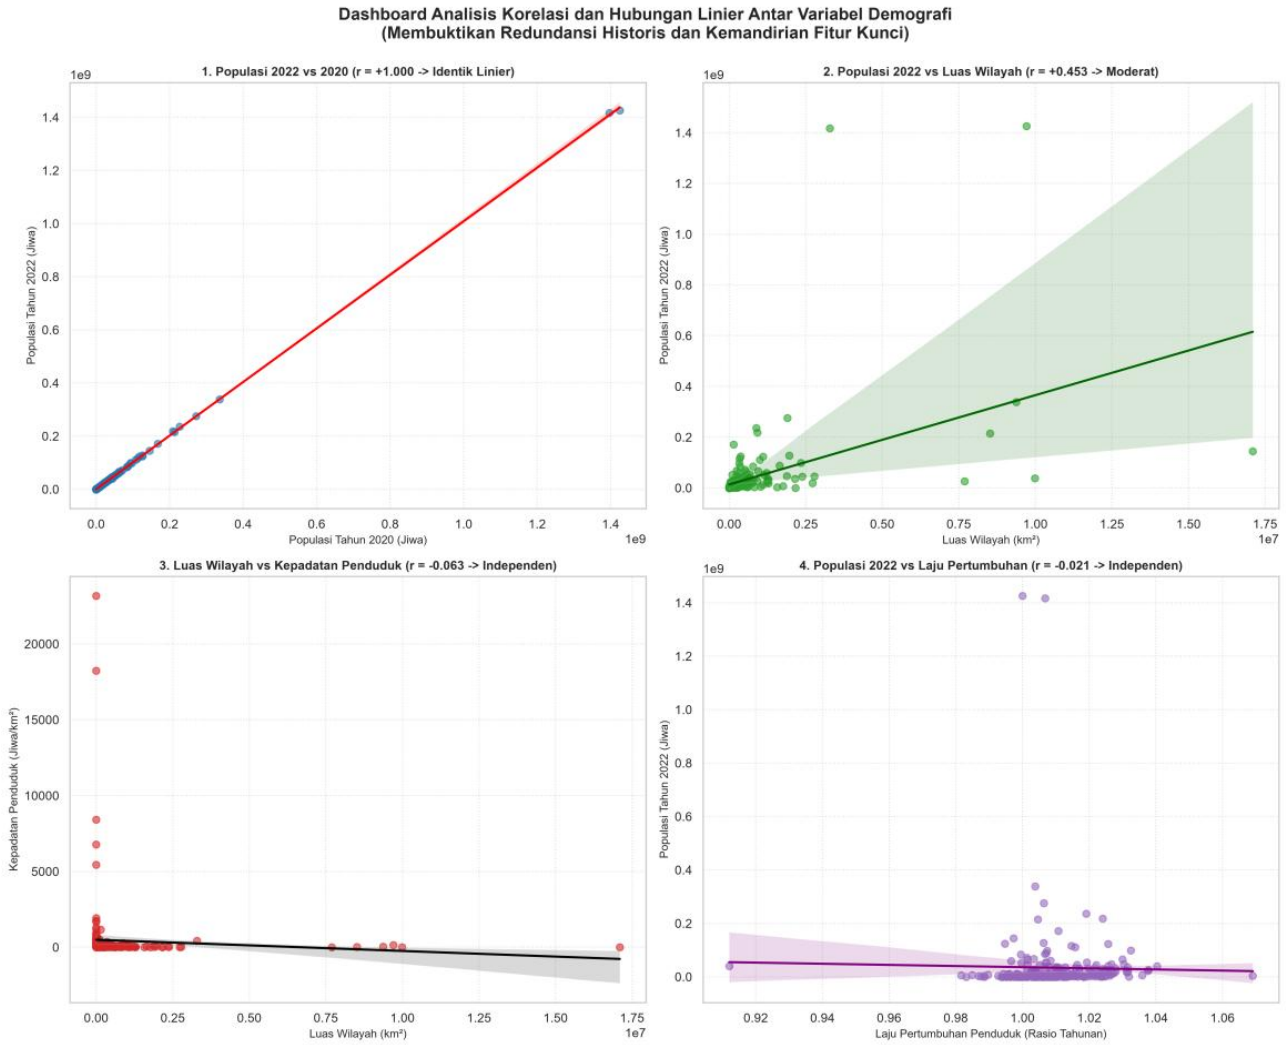
4.3 Uji Multikolinearitas Antarvariabel

Koefisien korelasi Pearson (r) mengukur hubungan linear dua variabel: r = ±1 berarti identik secara linear (redundan), r mendekati 0 berarti saling bebas. Kode 4.2 menghitung matriks korelasi lalu menggambar empat diagram pencar dengan garis regresi (`sns.regplot`) untuk pasangan yang paling menentukan keputusan pemilihan fitur.

KODE 4.2 **Matriks korelasi Pearson dan diagram pencar regresi (Gambar 2)**

```
fitur_korelasi = ['2022 Population', '2020 Population', '2010 Population',
                  'Area (km²)', 'Density (per km²)', 'Growth Rate']
display(df[fitur_korelasi].corr(method='pearson').round(3))       # matriks korelasi

pasangan = [   # (sumbu x, sumbu y, warna titik, warna garis regresi)
    ('2020 Population', '2022 Population',   '#1f77b4', 'red'),
    ('Area (km²)',      '2022 Population',   '#2ca02c', 'darkgreen'),
    ('Area (km²)',      'Density (per km²)', '#d62728', 'black'),
    ('Growth Rate',     '2022 Population',   '#9467bd', 'purple'),
]
fig, axes = plt.subplots(nrows=2, ncols=2, figsize=(16, 13))
for ax, (x, y, c_titik, c_garis) in zip(axes.ravel(), pasangan):
    r = df[x].corr(df[y])                                  # koefisien Pearson pasangan ini
    sns.regplot(data=df, x=x, y=y, ax=ax,
                scatter_kws={'alpha': 0.6, 'color': c_titik, 's': 40},
                line_kws={'color': c_garis, 'linewidth': 2})
    ax.set_title(f'{y} vs {x} (r = {r:+.3f})')
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'eda_scatter_korelasi.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 2. Diagram pencar korelasi antarvariabel demografi (titik biru: redundan; lainnya: independen).

Pasangan variabel	r (Pearson)	Tafsiran
Populasi 2022 vs 2020	+1,000	Identik linear: redundan sempurna (multikolinearitas)

Pasangan variabel	r (Pearson)	Tafsiran
Populasi 2022 vs Luas Wilayah	+0,453	Moderat: berhubungan tetapi tidak identik
Luas Wilayah vs Kepadatan	−0,063	Independen: tiap variabel membawa informasi unik
Populasi 2022 vs Laju Pertumbuhan	−0,021	Independen: tiap variabel membawa informasi unik

Justifikasi eliminasi fitur historis

1. Multikolinearitas sempurna. Populasi 2022 dan 2020 membentuk garis diagonal lurus (r = 1,00): kolom populasi antartahun membawa informasi yang sama.

2. Bahaya bias bobot 73%. Jika kedelapan kolom populasi historis dimasukkan, ukuran populasi menguasai 8 dari 11 kolom (8/11 ≈ 73%). Jarak Euclidean K-Means akan didominasi satu dimensi, sedangkan luas, kepadatan, dan pertumbuhan hampir diabaikan. Tujuh kolom lama dieliminasi dan hanya *2022 Population* dipertahankan.

3. Kemandirian fitur. Luas vs Kepadatan (r = −0,06) dan Populasi vs Pertumbuhan (r = −0,02) menyebar acak, sehingga keempat fitur terpilih saling melengkapi.

4.4 Seleksi Empat Pilar Fitur Demografi Kunci

Berdasarkan uji independensi, dipilih empat pilar yang mewakili dimensi demografi secara menyeluruh:

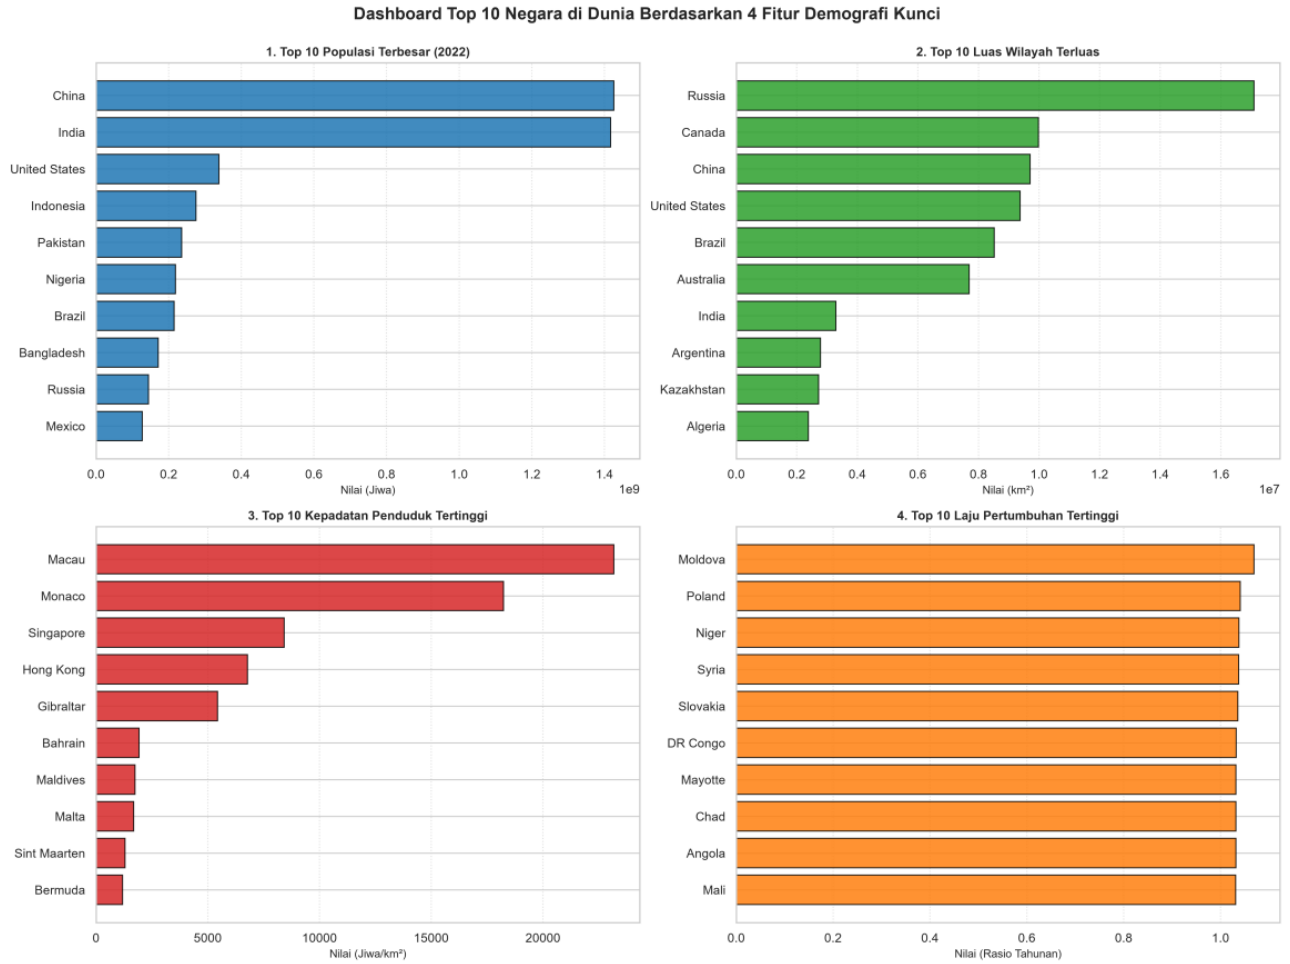
1. **2022 Population**: besaran kuantitas penduduk terkini.
2. **Area (km²)**: bentang geografis dan kapasitas ruang fisik daratan.
3. **Density (per km²)**: tingkat konsentrasi dan kepadatan ruang hunian.
4. **Growth Rate**: dinamika percepatan perubahan populasi tahunan.

Kode 4.3 mengisolasi keempat fitur ke DataFrame baru `df_features` dengan `.copy()` agar perubahan di tahap berikutnya tidak memengaruhi data asli. Dashboard 10 negara teratas per fitur memberi gambaran peringkat ekstrem pada setiap pilar.

KODE 4.3 Isolasi 4 fitur kunci dan dashboard Top 10 (Gambar 3)

```
fitur_clustering = ['2022 Population', 'Area (km²)', 'Density (per km²)', 'Growth Rate']
df_features = df[fitur_clustering].copy()          # salinan 234 x 4, aman dari efek samping

judul = ['Top 10 Populasi Terbesar (2022)', 'Top 10 Luas Wilayah Terluas',
         'Top 10 Kepadatan Tertinggi', 'Top 10 Laju Pertumbuhan Tertinggi']
warna = ['#1f77b4', '#2ca02c', '#d62728', '#ff7f0e']
fig, axes = plt.subplots(nrows=2, ncols=2, figsize=(16, 12))
for i, col in enumerate(fitur_clustering):
    ax = axes[divmod(i, 2)]                        # (baris, kolom) dari nomor fitur
    top10 = df.sort_values(by=col, ascending=False).head(10).iloc[::-1]   # peringkat 1 di atas
    ax.barh(top10['Country/Territory'], top10[col], color=warna[i], edgecolor='black')
    ax.set_title(judul[i])
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'eda_top10_fitur_terpilih.png', dpi=300, bbox_inches='tight')
plt.show()
```

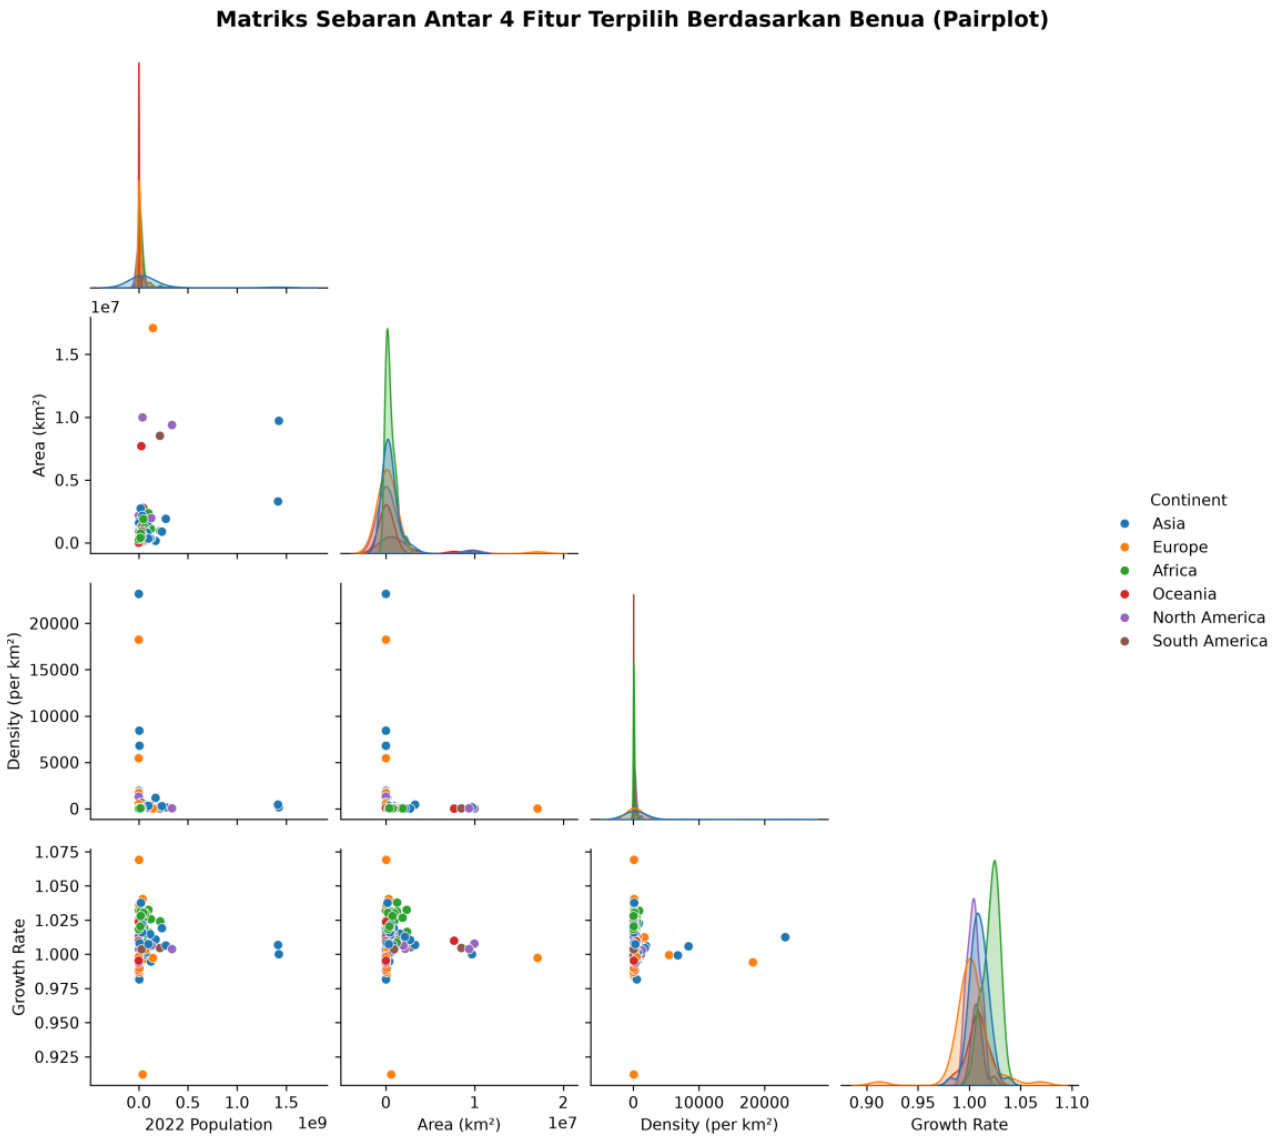


Gambar 3. Peringkat 10 negara teratas berdasarkan empat fitur demografi kunci.

Matriks sebaran antarkeempat fitur, diwarnai menurut benua, memperlihatkan bahwa titik-titik benua yang sama menyebar di mana-mana pada ruang fitur. Ini adalah bukti awal bahwa benua bukan dasar pengelompokan demografi yang baik. Kode 4.4 adalah kode pelengkap untuk grafik tersebut.

KODE 4.4 · PELENGKAP **Matriks sebaran (pairplot) 4 fitur berdasarkan benua (Gambar 4)**

```
sns.pairplot(df, vars=fitur_clustering, hue='Continent', corner=True, diag_kind='kde')
plt.savefig(OUTPUT_DIR / 'eda_pairplot_benua.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 4. *Matriks pairplot sebaran multivariat empat fitur terpilih, diwarnai menurut benua.*

BAB 5 · UNIT KOMPETENSI 5

Membersihkan Data

Kode unit: J.62DMI00.008.1

Unit ini menangani pencilan dan sebaran menceng dengan prinsip **Zero Data Loss**: tidak ada satu baris pun yang dibuang. Pembersihan di sini bukan menghapus data, melainkan meredam rentang yang masif lewat transformasi matematika.

5.1 Filosofi Penanganan Outlier: Zero Data Loss

Dalam data kependudukan global, China dan India (lebih dari 1,4 miliar jiwa) serta Rusia (lebih dari 17 juta km²) adalah pencilan *alami* yang sah, bukan kesalahan input. Menghapusnya berarti membuang sekitar sepertiga penduduk bumi dari analisis, sebuah kesalahan fatal. Karena itu pencilan dipertahankan, dan skalanya dikompresi dengan logaritma.

5.2 Transformasi Logaritma Natural (np.log1p)

Transformasi yang dipakai adalah **y = ln(x + 1)**. Fungsi `np.log1p` dipilih, bukan `np.log` biasa, karena aman terhadap nilai nol: ln(0 + 1) = 0, sedangkan log(0) menghasilkan tak hingga dan error. Transformasi ini menekan jarak antara negara raksasa dan negara biasa, serta mengubah sebaran menceng ekstrem menjadi mendekati simetris. Transformasi diterapkan pada tiga fitur berentang lebar (Populasi, Luas, Kepadatan). *Growth Rate* tidak ditransformasi karena sudah berskala rasio kecil (sekitar 0,91 hingga 1,07).

KODE 5.1 Transformasi log1p dan perbandingan skewness

```
fitur_wajib_log = ['2022 Population', 'Area (km²)', 'Density (per km²)']   # skewness > +6
df_log = df_features.copy()
for col in fitur_wajib_log:
    df_log[f'Log_{col}'] = np.log1p(df_features[col])        # y = ln(x + 1), aman untuk nilai 0
# 'Growth Rate' sengaja tidak di-log: sudah berskala rasio wajar

komparasi_skew = pd.DataFrame({
    'Fitur':   fitur_wajib_log,
    'Sebelum': [df_features[c].skew() for c in fitur_wajib_log],
    'Sesudah': [df_log[f'Log_{c}'].skew() for c in fitur_wajib_log],
})
komparasi_skew['Penurunan'] = komparasi_skew['Sebelum'] - komparasi_skew['Sesudah']
display(komparasi_skew.round(3))
```

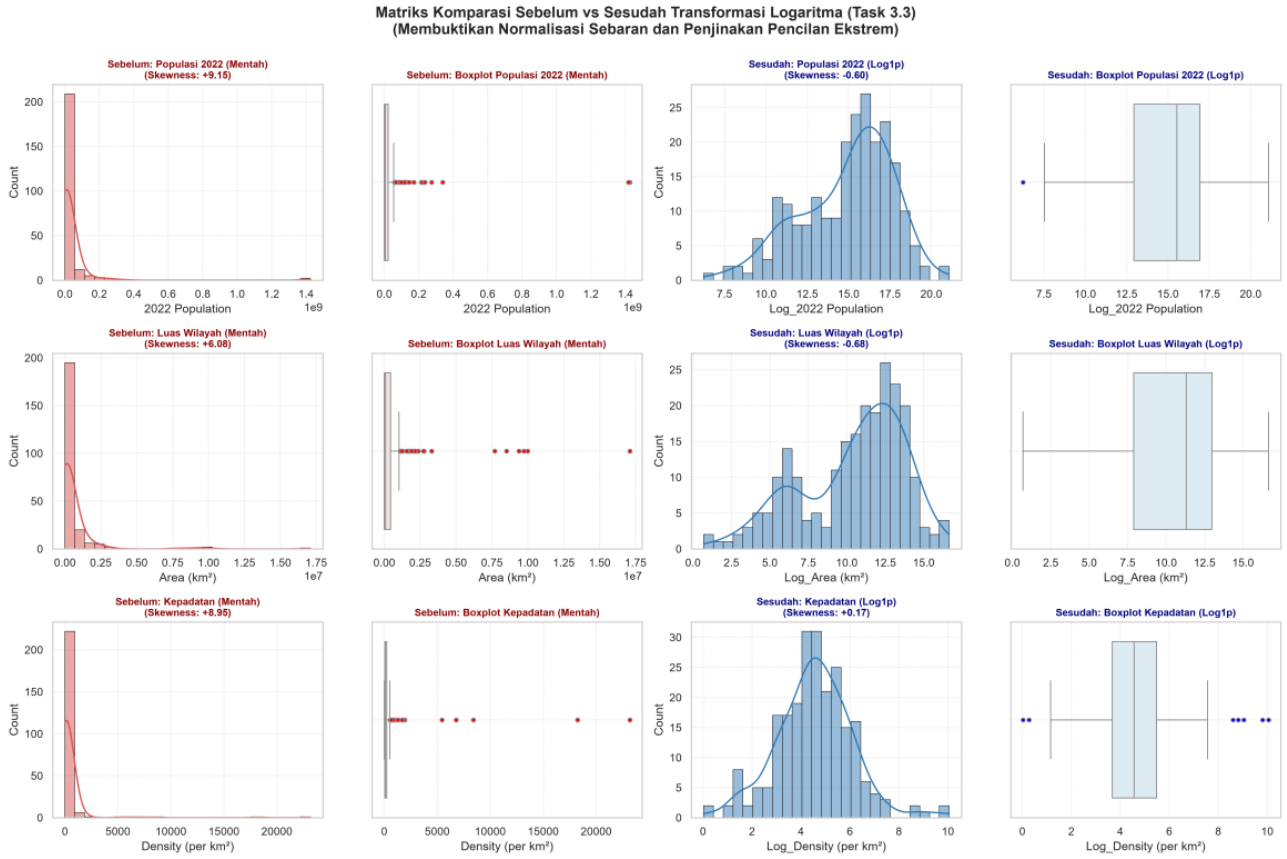
5.3 Evaluasi Penurunan Skewness dan Normalisasi Sebaran

Fitur	Skewness sebelum	Skewness sesudah log1p	Status
Populasi 2022	+9,151	−0,604	Mendekati lonceng normal
Luas Wilayah	+6,082	−0,678	Mendekati lonceng normal
Kepadatan	+8,949	+0,172	Sangat simetris, mendekati 0

Seluruh 234 negara tetap berada di dalam `df_log`. Kode 5.2 menyusun grid 3 baris × 4 kolom: dua kolom kiri (merah) menampilkan histogram-KDE dan boxplot data mentah, dua kolom kanan (biru) menampilkan data yang sama setelah log1p.

KODE 5.2 **Visual perbandingan sebelum dan sesudah transformasi (Gambar 5)**

```
fitur_log_list = [f'Log_{c}' for c in fitur_wajib_log]
fig, axes = plt.subplots(nrows=3, ncols=4, figsize=(18, 12))
for row, (raw, log) in enumerate(zip(fitur_wajib_log, fitur_log_list)):
    sns.histplot(df_features[raw], kde=True, bins=25, ax=axes[row, 0], color='#d9534f')   # sebelum
    sns.boxplot(x=df_features[raw], ax=axes[row, 1], color='#f2dede')
    sns.histplot(df_log[log], kde=True, bins=25, ax=axes[row, 2], color='#337ab7')        # sesudah
    sns.boxplot(x=df_log[log], ax=axes[row, 3], color='#d9edf7')
    axes[row, 0].set_title(f'Sebelum: {raw} (skew {df_features[raw].skew():+.2f})')
    axes[row, 2].set_title(f'Sesudah: {log} (skew {df_log[log].skew():+.2f})')
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'perbandingan_sebelum_sesudah_preprocessing.png',
            dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 5. Perbandingan kurva distribusi sebelum dan sesudah transformasi logaritma.

Hasil Bab 5

Kemencengan turun lebih dari 90% menuju zona simetris tanpa kehilangan satu negara pun. Data kini bersih secara bentuk sebaran dan siap distandarisasi pada Bab 6.

BAB 6 · UNIT KOMPETENSI 6

Mengkonstruksi Data

Kode unit: J.62DMI00.009.1

Unit ini mengonstruksi data siap-latih melalui standardisasi skala Z-Score, sehingga keempat fitur berkontribusi seimbang pada perhitungan jarak K-Means.

6.1 Standardisasi Skala Z-Score (StandardScaler)

K-Means mengandalkan jarak Euclidean, yaitu akar dari jumlah kuadrat selisih pada setiap dimensi. Tanpa penyetaraan skala, variabel berangka besar (luas dalam jutaan km²) akan mendominasi jarak hingga hampir 99,9%, sedangkan variabel berangka kecil (pertumbuhan, skala 1,01) praktis diabaikan. Standardisasi mengubah tiap fitur menjadi **z = (x − rata-rata) / simpangan baku**, sehingga masing-masing berpusat di 0 dengan simpangan baku 1.

Kode 6.1 menerapkan `StandardScaler` pada empat fitur siap-latih: tiga hasil log1p ditambah Growth Rate asli. Objek `scaler` disimpan karena dibutuhkan lagi untuk membalik skala centroid (Bab 8) dan memproses data baru (Bab 8.4).

KODE 6.1 Standardisasi Z-Score dan verifikasi mean serta simpangan baku

```
from sklearn.preprocessing import StandardScaler

fitur_siap_scale = ['Log_2022 Population', 'Log_Area (km²)',
                    'Log_Density (per km²)', 'Growth Rate']
nama_scaled = ['Scale_Population', 'Scale_Area', 'Scale_Density', 'Scale_GrowthRate']

scaler = StandardScaler()
X_scaled = scaler.fit_transform(df_log[fitur_siap_scale])    # fit: mean & std; transform: z-score
df_scaled = pd.DataFrame(X_scaled, columns=nama_scaled, index=df.index)

display(pd.DataFrame({                                       # target: mean = 0, std = 1
    'Fitur': fitur_siap_scale,
    'Mean':  df_scaled.mean().abs().round(4).values,
    'Std':   df_scaled.std(ddof=0).round(4).values,  # ddof=0, konvensi StandardScaler
    'Min':   df_scaled.min().round(4).values,
    'Max':   df_scaled.max().round(4).values,
}))
```

Catatan teknis: ddof=0

StandardScaler memakai simpangan baku populasi (ddof=0), sedangkan `DataFrame.std()` bawaan pandas memakai ddof=1 dan akan menampilkan 1,0021, bukan 1,0000. Verifikasi di atas memakai ddof=0 agar sebanding dengan perhitungan scaler.

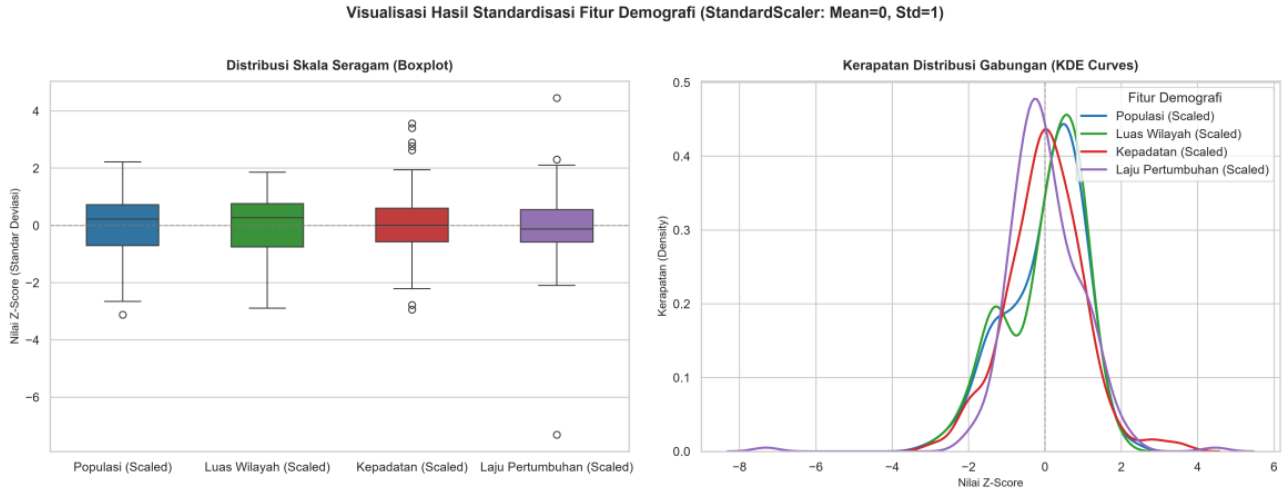
6.2 Validasi Fitur Terstandarisasi

Hasil verifikasi membuktikan keempat fitur terpusat pada rata-rata 0,0000 dengan simpangan baku 1,0000. Setiap variabel kini memberi bobot kontribusi seimbang (25% masing-masing) pada K-Means. Kode 6.2 memvisualisasikannya dengan boxplot gabungan pada sumbu Z-Score yang sama dan kurva KDE bersama.

KODE 6.2 **Visual sebaran fitur terstandarisasi (Gambar 6)**

```
palette = ['#1f77b4', '#2ca02c', '#d62728', '#9467bd']
label_display = ['Populasi (Scaled)', 'Luas Wilayah (Scaled)',
                 'Kepadatan (Scaled)', 'Laju Pertumbuhan (Scaled)']
df_plot = df_scaled.copy()
df_plot.columns = label_display

fig, (ax1, ax2) = plt.subplots(nrows=1, ncols=2, figsize=(16, 6))
sns.boxplot(data=df_plot, ax=ax1, palette=palette, width=0.5)      # kiri: boxplot satu sumbu Z
ax1.axhline(0, color='gray', linestyle='--', linewidth=1)
for warna, kolom in zip(palette, label_display):                   # kanan: kurva KDE bersama
    sns.kdeplot(df_plot[kolom], ax=ax2, color=warna, label=kolom, linewidth=2)
ax2.axvline(0, color='gray', linestyle='--', linewidth=1)
ax2.legend(title='Fitur Demografi')
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'eda_standardized_features.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 6. Distribusi boxplot dan KDE empat fitur demografi setelah standardisasi Z-Score.

Hasil Bab 6

Matriks `X_scaled` berukuran 234 × 4 siap dimasukkan ke Bab 7. Objek `scaler` dan `X_scaled` dipakai ulang pada Bab 7 (penentuan K) dan Bab 8 (pelatihan, pembalikan skala, serialisasi).

BAB 7 · UNIT KOMPETENSI 7

Menentukan Label Data

Kode unit: J.62DMI00.010.1

Unit ini menentukan jumlah klaster optimal (K) lewat dua uji yang saling melengkapi, Elbow Method dan Silhouette Score, lalu menetapkan taksonomi label demografi resmi. Pada K-Means jumlah klaster harus ditentukan sebelum pelatihan, sehingga keputusan ini menentukan kualitas seluruh hasil.

7.1 Elbow Method: Inersia WCSS

Inertia atau *Within-Cluster Sum of Squares* (WCSS) adalah total kuadrat jarak Euclidean antara tiap titik dan pusat klasternya. Semakin banyak klaster, inersia pasti turun; pertanyaannya di mana penurunan itu mulai melandai (membentuk "siku"). Kode 7.1 melatih K-Means untuk K = 1 sampai 10 dan mencatat inersia serta persentase penurunannya dari K sebelumnya. Parameter yang sama dipakai pada setiap percobaan: `init='k-means++'` (pusat awal dipilih saling berjauhan agar tidak terjebak optimum lokal), `n_init=10` (10 kali restart, dipilih yang inersianya terendah), `max_iter=300`, dan `random_state=42` (hasil dapat direproduksi).

KODE 7.1 Perhitungan inersia WCSS untuk K = 1 sampai 10

```
from sklearn.cluster import KMeans

k_range = list(range(1, 11))
wcss_scores = []
for k in k_range:
    km = KMeans(n_clusters=k, init='k-means++', n_init=10, max_iter=300, random_state=42)
    km.fit(X_scaled)
    wcss_scores.append(km.inertia_)                        # WCSS model dengan k klaster

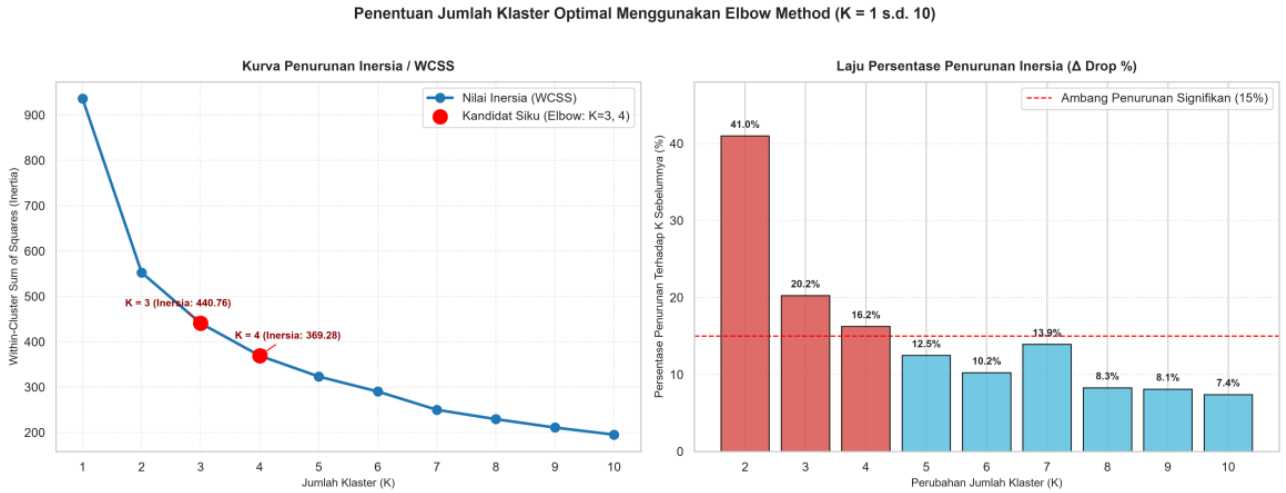
df_elbow = pd.DataFrame({'K': k_range, 'Inertia': wcss_scores})
df_elbow['Delta'] = df_elbow['Inertia'].diff().abs()                          # selisih antar-K
df_elbow['Pct_Drop'] = df_elbow['Delta'] / df_elbow['Inertia'].shift(1) * 100  # persentase turun
display(df_elbow.round(4))
```

Kode 7.2 menggambar kurva inersia (panel kiri, dengan penanda kandidat siku K = 3 dan K = 4) dan diagram batang persentase penurunan dengan garis ambang 15% (panel kanan).

KODE 7.2 Kurva Elbow dan persentase penurunan inersia (Gambar 7)

```
fig, (ax1, ax2) = plt.subplots(nrows=1, ncols=2, figsize=(16, 6))
ax1.plot(k_range, wcss_scores, marker='o', markersize=8, linewidth=2.5, color='#1f77b4')
ax1.scatter([3, 4], [wcss_scores[2], wcss_scores[3]], color='red', s=160, zorder=5)  # kandidat siku
ax1.set_xlabel('Jumlah Klaster (K)')
ax1.set_ylabel('Inersia (WCSS)')

pct_drops = df_elbow['Pct_Drop'].dropna().values
warna_bar = ['#d9534f' if p >= 15 else '#5bc0de' for p in pct_drops]  # merah: signifikan
ax2.bar(k_range[1:], pct_drops, color=warna_bar, edgecolor='black')
ax2.axhline(15, color='red', linestyle='--', label='Ambang penurunan signifikan (15%)')
ax2.set_xlabel('Perubahan Jumlah Klaster (K)')
ax2.set_ylabel('Penurunan terhadap K sebelumnya (%)')
ax2.legend()
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'model_elbow_method.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 7. Kurva Elbow Method (inersia WCSS) dengan kandidat siku pada K = 3 dan K = 4.

Hasil. Inersia turun dari 936,00 (K = 1, total varians 234 negara × 4 fitur) menjadi 552,58 (K = 2), 440,76 (K = 3), 369,28 (K = 4), dan 323,30 (K = 5). Penurunan dari K = 3 ke K = 4 (−16,22%) adalah penurunan terakhir yang masih di atas ambang 15%; sesudahnya kurva melandai (diminishing returns). Pada K = 4, inersia sudah terpangkas 60,5% dari baseline.

7.2 Silhouette Score: Kohesi dan Separasi Klaster

Elbow hanya melihat kekompakan di dalam klaster. Silhouette menambahkan sudut pandang kedua: seberapa terpisah sebuah klaster dari klaster tetangga. Untuk tiap titik i dihitung **s(i) = (b(i) − a(i)) / max(a(i), b(i))**, dengan a(i) rata-rata jarak ke titik lain di klaster yang sama (kohesi) dan b(i) rata-rata jarak ke klaster tetangga terdekat (separasi). Rentang nilainya −1 hingga +1; skor di atas sekitar 0,30 umumnya dianggap menunjukkan struktur klaster yang layak. Silhouette membutuhkan minimal dua klaster, sehingga dihitung untuk K = 2 sampai 10.

KODE 7.3 Perhitungan Silhouette Score untuk K = 2 sampai 10

```
from sklearn.metrics import silhouette_score

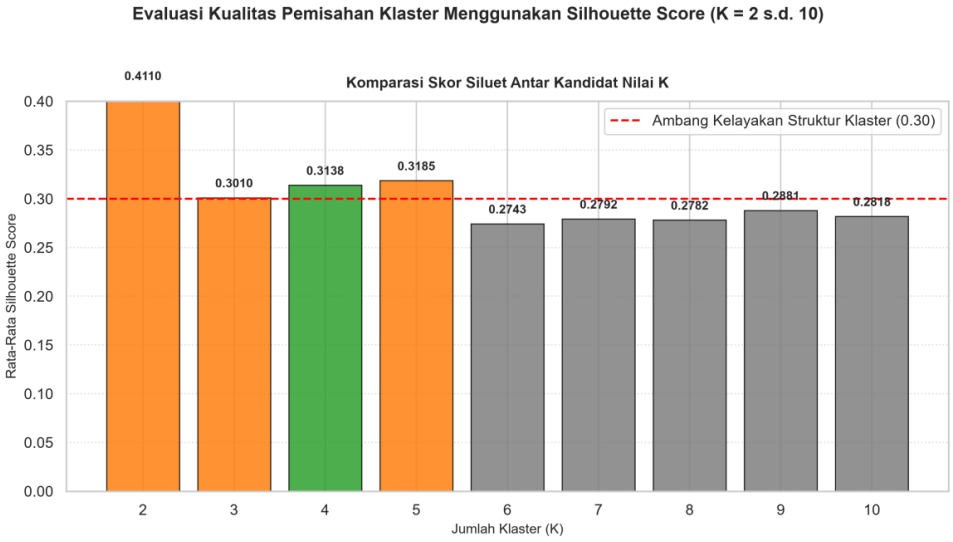
k_sil_range = list(range(2, 11))
silhouette_scores = []
for k in k_sil_range:
    labels = KMeans(n_clusters=k, init='k-means++', n_init=10, max_iter=300,
                    random_state=42).fit_predict(X_scaled)          # label klaster tiap negara
    silhouette_scores.append(silhouette_score(X_scaled, labels))    # rata-rata s(i)

df_silhouette = pd.DataFrame({'K': k_sil_range, 'Silhouette': silhouette_scores})
display(df_silhouette.round(4))
```

KODE 7.4 Diagram batang Silhouette Score (Gambar 8)

```
warna = ['#2ca02c' if k == 4 else ('#ff7f0e' if s >= 0.30 else '#7f7f7f')   # hijau: K=4
         for k, s in zip(k_sil_range, silhouette_scores)]
fig, ax = plt.subplots(figsize=(10, 5.5))
bars = ax.bar(k_sil_range, silhouette_scores, color=warna, edgecolor='black')
for b in bars:                                                          # angka di atas batang
    ax.text(b.get_x() + b.get_width() / 2, b.get_height() + 0.008,
            f'{b.get_height():.4f}', ha='center', fontsize=9, fontweight='bold')
ax.axhline(0.30, color='red', linestyle='--', label='Ambang kelayakan struktur klaster (0.30)')
ax.set_xlabel('Jumlah Klaster (K)')
ax.set_ylabel('Rata-rata Silhouette Score')
ax.legend()
plt.tight_layout()
```

```
plt.savefig(OUTPUT_DIR / 'model_silhouette_scores.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 8. Skor koefisien Silhouette untuk K = 2 sampai 10 (hijau: K = 4; garis merah: ambang 0,30).

7.3 Keputusan Final: K = 4

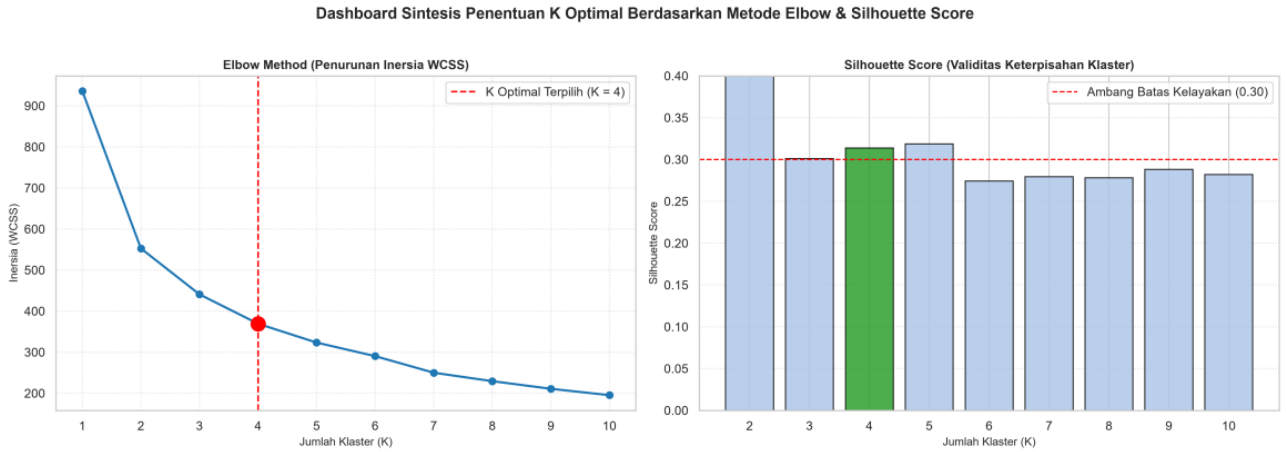
Keputusan memadukan tiga kriteria: Elbow (kekompakan), Silhouette (keterpisahan), dan kelayakan domain sosio-demografi (apakah klaster bermakna dan seimbang). Kode 7.5 menetapkan `K_OPTIMAL = 4` dan menyatukan kedua grafik dalam satu dashboard.

KODE 7.5 Penetapan K optimal dan dashboard sintesis (Gambar 9)

```
K_OPTIMAL = 4                                                    # keputusan final, dipakai di Bab 8

fig, (ax1, ax2) = plt.subplots(nrows=1, ncols=2, figsize=(16, 5.5))
ax1.plot(k_range, wcss_scores, marker='o', color='#1f77b4', linewidth=2)
ax1.axvline(K_OPTIMAL, color='red', linestyle='--', label=f'K terpilih = {K_OPTIMAL}')
ax1.scatter([K_OPTIMAL], [wcss_scores[K_OPTIMAL - 1]], color='red', s=160, zorder=5)
ax1.set_title('Elbow Method (inersia WCSS)')
ax1.legend()

ax2.bar(k_sil_range, silhouette_scores, edgecolor='black',
        color=['#2ca02c' if k == K_OPTIMAL else '#aec7e8' for k in k_sil_range])
ax2.axhline(0.30, color='red', linestyle='--', label='Ambang kelayakan (0.30)')
ax2.set_title('Silhouette Score (keterpisahan klaster)')
ax2.legend()
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'model_evaluasi_k_optimal.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 9. Panel gabungan evaluasi metrik K optimal: Elbow (kiri) dan Silhouette (kanan).

K	Inersia WCSS	Penurunan	Silhouette	Anggota klaster	Keputusan dan alasan
2	552,58	−40,96%	0,4110	166 dan 68	**Ditolak (terlalu dangkal).** Skor tertinggi, tetapi hanya membagi negara menjadi dua kubu dan menghilangkan arketipe negara-kota mikro padat vs negara luas renggang.
3	440,76	−20,24%	0,3010	86, 84, 64	**Ditolak (separasi lemah).** Skor hanya sedikit di atas ambang dan lebih rendah dari K = 4; negara berkembang cepat masih bercampur dengan negara mapan.
4	**369,28**	**−16,22%**	**0,3138**	**71, 64, 54, 45**	**Dipilih.** Penurunan inersia signifikan terakhir sebelum kurva melandai; skor di atas ambang dan lebih baik dari K = 3; anggota seimbang, tanpa klaster kerdil; empat profil bermakna.
5	323,30	−12,45%	0,3185	75, 64, 49, 45, 1	**Ditolak (over-segmentation).** Skor sedikit lebih tinggi, tetapi terbentuk klaster singleton beranggota satu negara sehingga tidak berguna untuk kebijakan.
6	290,27	−10,22%	0,2743	terlalu terpecah	**Ditolak (degradasi).** Skor di bawah ambang 0,30; batas antarkelompok kabur dan penurunan inersia sudah jenuh.

Catatan kejujuran metodologis

K = 4 bukan skor Silhouette tertinggi mutlak: K = 2 (0,4110) dan K = 5 (0,3185) lebih tinggi. K = 4 dipilih karena **kombinasi** kriteria: titik siku Elbow, skor di atas ambang 0,30 dan lebih tinggi daripada K = 3, tidak adanya klaster singleton, dan kebermaknaan profil. Skor sekitar 0,31 menunjukkan struktur klaster yang layak tetapi tidak terpisah sangat tegas; wajar untuk data demografi yang kontinu.

7.4 Taksonomi Label Resmi (Business Labeling)

Nomor klaster 0 sampai 3 hanyalah penanda. Agar bermakna bagi pengambil kebijakan, tiap klaster diberi nama berdasarkan karakteristik statistik riilnya (lihat profil di Bab 9.6). Kode 7.6 menempelkan label numerik ke dataset lalu memetakan nomor itu ke nama demografi lewat dictionary dan `.map()`.

Prasyarat eksekusi

Kode 7.6 memakai objek `kmeans_final` yang dilatih pada Kode 8.1. Di notebook, jalankan Kode 8.1 lebih dulu, baru Kode 7.6.

KODE 7.6 **Menempelkan label numerik dan nama klaster ke dataset**

```
df['Cluster'] = kmeans_final.labels_                # nomor klaster 0-3 untuk tiap negara
df_features['Cluster'] = kmeans_final.labels_

cluster_names_map = {
    0: 'Negara Berkembang Tumbuh Pesat',
    1: 'Negara-Kota Mikro & Kepulauan Padat',
    2: 'Negara Megapopulasi Mapan',
    3: 'Negara Teritorial Luas & Renggang',
}
df['Cluster_Name'] = df['Cluster'].map(cluster_names_map)      # nomor -> julukan bermakna
df_features['Cluster_Name'] = df['Cluster_Name']
```

Klaster	Nama	Negara	Pangsa populasi	Karakter utama
0	Negara Berkembang Tumbuh Pesat	54 (23,08%)	24,07%	Laju pertumbuhan tertinggi (rata-rata +2,50%/tahun); Afrika Sub-Sahara dan Asia berkembang (Pakistan, Nigeria, Ethiopia, Mesir, Filipina, Kenya).
1	Negara-Kota Mikro & Kepulauan Padat	64 (27,35%)	0,35%	Luas rata-rata hanya 821 km² dengan kepadatan rata-rata 1.338 jiwa/km² (hingga lebih dari 18.000) (Singapura, Hong Kong, Monako, Bahrain, Maladewa, Bermuda).
2	Negara Megapopulasi Mapan	71 (30,34%)	68,70%	Populasi rata-rata tertinggi (77,1 juta), pertumbuhan stabil rendah (+0,07%/tahun); menampung lebih dari dua pertiga umat manusia (China, India, AS, Indonesia, Brasil, Bangladesh, Jepang).
3	Negara Teritorial Luas & Renggang	45 (19,23%)	6,89%	Luas rata-rata 1,39 juta km² dengan kepadatan terendah (14,8 jiwa/km²) (Rusia, Kanada, Australia, Argentina, Aljazair, Arab Saudi).

BAB 8 · UNIT KOMPETENSI 8

Membangun Model

Kode unit: J.62DMI00.013.1

Unit ini melatih model K-Means final, mengekstraksi titik pusat (centroid) beserta rekonstruksi ke satuan asli, dan menyimpan model agar dapat dipakai ulang (deployment).

8.1 Konfigurasi dan Pelatihan K-Means++

Model final memakai konfigurasi yang sama dengan percobaan Bab 7, tetapi dengan `n_clusters=K_OPTIMAL`. Metode `.fit()` menjalankan algoritma Lloyd: menetapkan tiap negara ke centroid terdekat, menghitung ulang centroid sebagai rata-rata anggotanya, dan mengulang hingga posisi centroid stabil (konvergen). Atribut `n_iter_` melaporkan jumlah iterasi yang dibutuhkan.

KODE 8.1 Pelatihan model K-Means final (K = 4)

```
kmeans_final = KMeans(n_clusters=K_OPTIMAL, init='k-means++', n_init=10,
                      max_iter=300, random_state=42)
kmeans_final.fit(X_scaled)                          # pelatihan pada matriks 234 x 4 ber-Z-score

print(f'Klaster terbentuk : {K_OPTIMAL}')
print(f'Iterasi konvergen : {kmeans_final.n_iter_}')
print(f'Inersia akhir     : {kmeans_final.inertia_:.4f}')      # harus sama dengan WCSS K=4 (369.28)
```

Hasil. Model konvergen dengan inersia akhir 369,28, identik dengan nilai K = 4 pada Elbow Method; ini sekaligus memverifikasi bahwa konfigurasi final konsisten dengan percobaan sebelumnya.

8.2 Ekstraksi Titik Pusat Massa (Centroid)

Atribut `cluster_centers_` menyimpan koordinat centroid pada skala Z-Score, sehingga nilainya berarti "seberapa jauh dari rata-rata dunia" dalam satuan simpangan baku. Agar dapat dibaca dalam satuan fisik, koordinat dikembalikan dengan dua langkah pembalikan yang urutannya terbalik dari pra-pemrosesan: (1) `scaler.inverse_transform()` membalik standardisasi menjadi skala logaritmik, lalu (2) `np.expm1()` membalik log1p untuk Populasi, Luas, dan Kepadatan. Growth Rate dipakai langsung karena tidak pernah di-log. Karena yang dibalik adalah rata-rata dari data berlogaritma, hasilnya berupa **rata-rata geometrik**, ukuran pemusatan yang kebal terhadap pencilan ekstrem.

KODE 8.2 Centroid skala Z-Score dan rekonstruksi ke satuan fisik asli

```
centroids_scaled = kmeans_final.cluster_centers_                    # skala Z-Score
nama_klaster = [f'Klaster {i}' for i in range(K_OPTIMAL)]
df_centroids_scaled = pd.DataFrame(centroids_scaled, columns=fitur_clustering, index=nama_klaster)

centroids_log = scaler.inverse_transform(centroids_scaled)          # (1) balik standardisasi
centroids_original = centroids_log.copy()
centroids_original[:, :3] = np.expm1(centroids_log[:, :3])          # (2) balik log1p (3 fitur)
df_centroids_original = pd.DataFrame(centroids_original, columns=fitur_clustering,
                                     index=nama_klaster)            # Growth Rate: tanpa log

display(df_centroids_original.round(4))       # satuan asli (rata-rata geometrik)
display(df_centroids_scaled.round(3))         # skala Z-Score
```

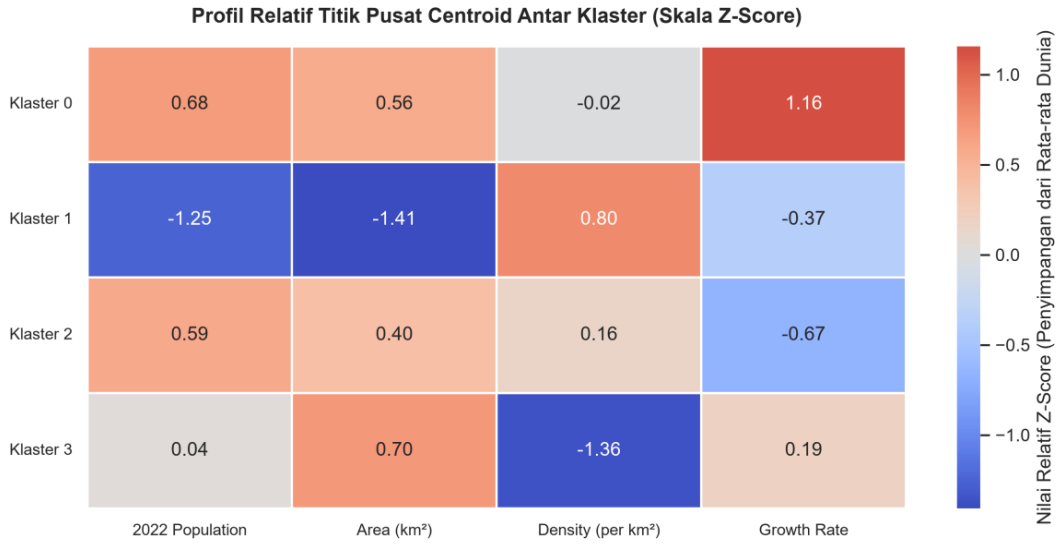
Centroid (Z-Score)	Populasi	Luas Wilayah	Kepadatan	Laju Pertumbuhan	Tafsiran
Klaster 0	+0,68	+0,56	−0,02	**+1,16**	Pertumbuhan jauh di atas dunia

Centroid (Z-Score)	Populasi	Luas Wilayah	Kepadatan	Laju Pertumbuhan	Tafsiran
Klaster 1	**−1,25**	**−1,41**	+0,80	−0,37	Sangat kecil dan padat
Klaster 2	+0,59	+0,40	+0,16	**−0,67**	Besar, mapan, tumbuh lambat
Klaster 3	+0,04	+0,70	**−1,36**	+0,19	Luas dan sangat renggang

Heatmap pada Gambar 10 menyajikan tabel Z-Score di atas secara visual: merah berarti di atas rata-rata dunia, biru di bawahnya. Kode 8.3 adalah kode pelengkap untuk grafik ini.

KODE 8.3 · PELENGKAP Heatmap centroid skala Z-Score (Gambar 10)

```
plt.figure(figsize=(9, 5))
sns.heatmap(df_centroids_scaled.round(2), annot=True, cmap='coolwarm', center=0, linewidths=1)
plt.title('Profil Relatif Titik Pusat Centroid Antar Klaster (Skala Z-Score)')
plt.savefig(OUTPUT_DIR / 'model_heatmap_centroid.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 10. Heatmap nilai fitur pada titik pusat centroid tiap klaster (skala Z-Score).

8.3 Serialisasi Model dan Pipeline (Joblib)

Demi reproduktifitas dan deployment, dua artefak disimpan sebagai berkas biner dengan `joblib.dump()`: `model_kmeans.pkl` (arsitektur dan centroid terlatih) dan `scaler.pkl` (rata-rata dan simpangan baku hasil *fit*). Keduanya wajib disimpan: tanpa scaler, data baru tidak dapat dipetakan ke skala Z-Score yang identik dan prediksi klaster menjadi salah.

Kode 8.4 sekaligus menguji alur inferensi: berkas dimuat ulang dengan `joblib.load()`, lalu negara hipotetis "Atlantis Baru" diproses lewat pipeline yang identik dengan pelatihan: **log1p, scaler.transform(), lalu predict()**. Nama kolom masukan harus sama persis dengan nama kolom saat *fit*.

KODE 8.4 **Serialisasi model dan scaler, lalu uji inferensi data baru**

```
import joblib

MODEL_PATH  = OUTPUT_DIR / 'model_kmeans.pkl'
SCALER_PATH = OUTPUT_DIR / 'scaler.pkl'
joblib.dump(kmeans_final, MODEL_PATH)                  # simpan model terlatih
joblib.dump(scaler, SCALER_PATH)                       # simpan parameter standardisasi

loaded_kmeans = joblib.load(MODEL_PATH)                # muat ulang (simulasi backend / web app)
loaded_scaler = joblib.load(SCALER_PATH)

negara_baru = {'2022 Population': 45_000_000, 'Area (km²)': 120_000,
               'Density (per km²)': 375.0, 'Growth Rate': 1.024}      # negara hipotetis
sample_df = pd.DataFrame([{                            # kolom harus sama dengan saat fit scaler
    'Log_2022 Population':   np.log1p(negara_baru['2022 Population']),
    'Log_Area (km²)':        np.log1p(negara_baru['Area (km²)']),
    'Log_Density (per km²)': np.log1p(negara_baru['Density (per km²)']),
    'Growth Rate':           negara_baru['Growth Rate'],
}])
sample_scaled = loaded_scaler.transform(sample_df)     # skala Z-Score identik dengan pelatihan
klaster = int(loaded_kmeans.predict(sample_scaled)[0]) # klaster dengan centroid terdekat
print(f'Klaster {klaster}: {cluster_names_map[klaster]}')
```

Hasil Bab 8

Model dan scaler tersimpan di folder `output/` dan terbukti dapat dimuat ulang untuk memprediksi klaster negara baru. Simulator pada dashboard web (Bab 9.7) memakai prinsip yang sama: jarak Euclidean ke empat centroid.

BAB 9 · UNIT KOMPETENSI 9

Mengevaluasi Hasil Pemodelan

Kode unit: J.62DMI00.014.1

Unit ini mengevaluasi hasil klasterisasi dari beberapa sudut: sebaran spasial, distribusi anggota, komposisi benua, validasi multidimensi, profil statistik, ekspor dataset, dan rekomendasi kebijakan.

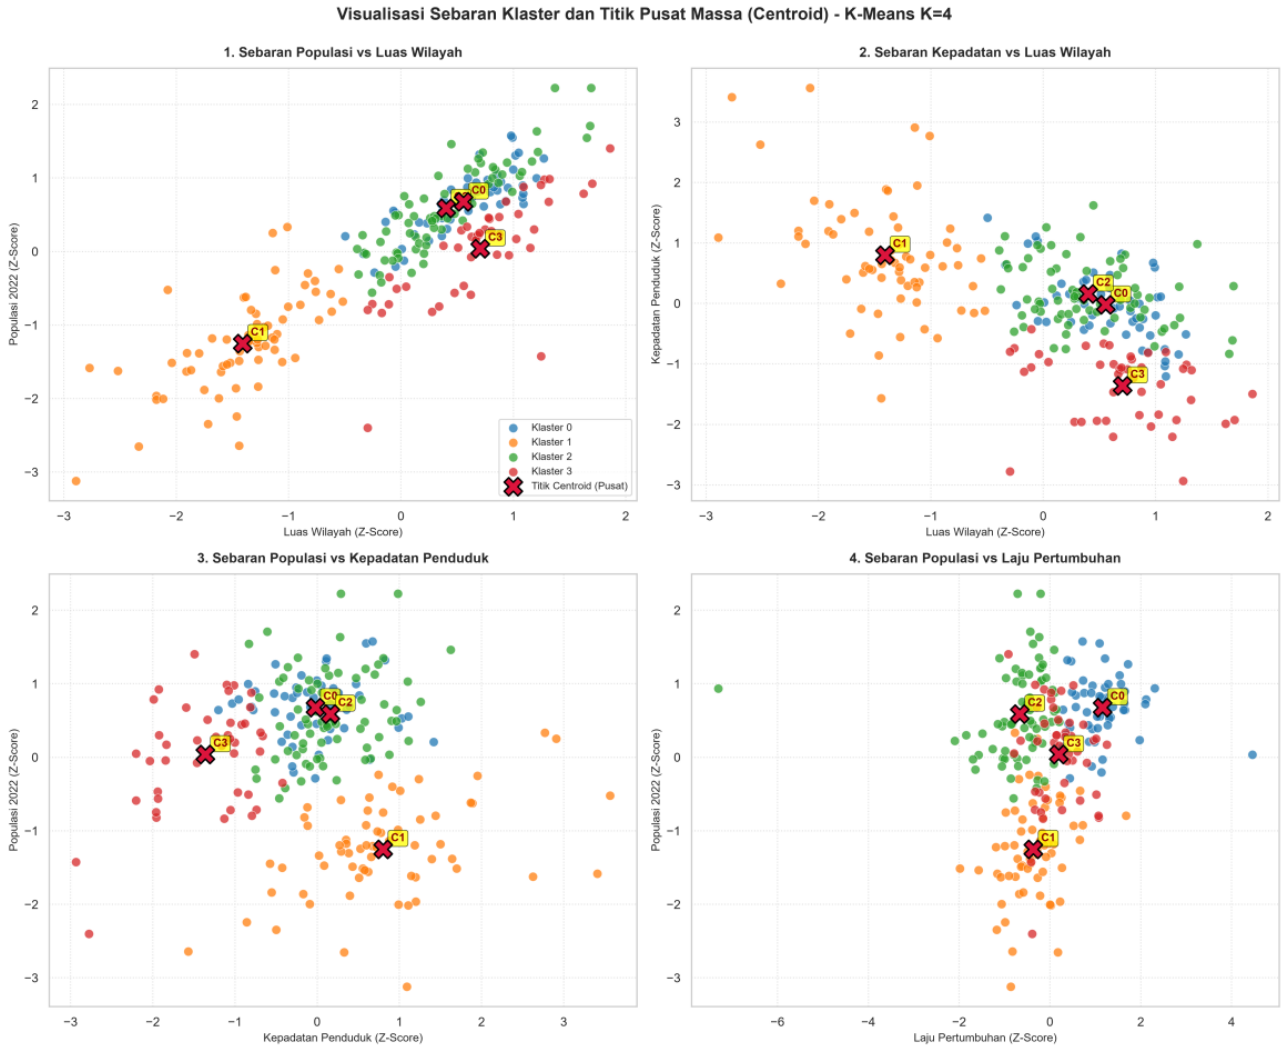
9.1 Sebaran Klaster dan Centroid pada Ruang Z-Score

Karena data berdimensi empat, sebaran divisualisasikan pada empat bidang 2D, masing-masing memplot sepasang fitur ber-Z-Score. Tiap negara diwarnai menurut klasternya, dan centroid ditandai simbol **X** merah berlabel C0 sampai C3. Kode 9.1 menggambar keempat bidang itu.

KODE 9.1 Scatter plot sebaran klaster dan centroid (Gambar 11)

```
df_scaled_plot = pd.DataFrame(X_scaled, columns=fitur_clustering)
df_scaled_plot['Cluster'] = df['Cluster']
cluster_colors = ['#1f77b4', '#ff7f0e', '#2ca02c', '#d62728']
pairs = [('Area (km²)', '2022 Population'), ('Area (km²)', 'Density (per km²)'),
         ('Density (per km²)', '2022 Population'), ('Growth Rate', '2022 Population')]

fig, axes = plt.subplots(nrows=2, ncols=2, figsize=(16, 13))
for ax, (x_col, y_col) in zip(axes.ravel(), pairs):
    for c in range(K_OPTIMAL):                                    # titik negara per klaster
        sub = df_scaled_plot[df_scaled_plot['Cluster'] == c]
        ax.scatter(sub[x_col], sub[y_col], color=cluster_colors[c], s=65, alpha=0.75,
                   edgecolor='white', linewidth=0.5, label=f'Klaster {c}')
    xi, yi = fitur_clustering.index(x_col), fitur_clustering.index(y_col)
    ax.scatter(centroids_scaled[:, xi], centroids_scaled[:, yi], c='crimson', s=260,
               marker='X', edgecolor='black', linewidth=1.5, zorder=10)       # centroid
    for c in range(K_OPTIMAL):
        ax.annotate(f'C{c}', (centroids_scaled[c, xi], centroids_scaled[c, yi]),
                    xytext=(7, 7), textcoords='offset points', fontweight='bold')
    ax.set_xlabel(x_col + ' (Z-Score)')
    ax.set_ylabel(y_col + ' (Z-Score)')
axes[0, 0].legend(loc='lower right')
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'model_centroid_scatterplot.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 11. Sebaran empat klaster dunia beserta posisi centroid pada empat bidang fitur ber-Z-Score.

Interpretasi Gambar 11

Klaster 2 (Megapopulasi Mapan) menempati sisi populasi dan luas tinggi, bergabung dengan China, India, AS, Indonesia, Brasil, Bangladesh, dan Jepang.

Klaster 1 (Mikro Padat) menumpuk di sisi kiri-bawah pada bidang populasi-luas (sangat kecil) tetapi naik ke atas pada sumbu kepadatan (Singapura, Hong Kong, Monako, Bahrain).

Klaster 3 (Luas Renggang) terpisah di sisi luas wilayah besar dengan kepadatan sangat rendah (Rusia, Kanada, Australia, Argentina).

Klaster 0 (Tumbuh Pesat) mendominasi sisi laju pertumbuhan tinggi pada bidang keempat (Pakistan, Nigeria, Ethiopia, Mesir).

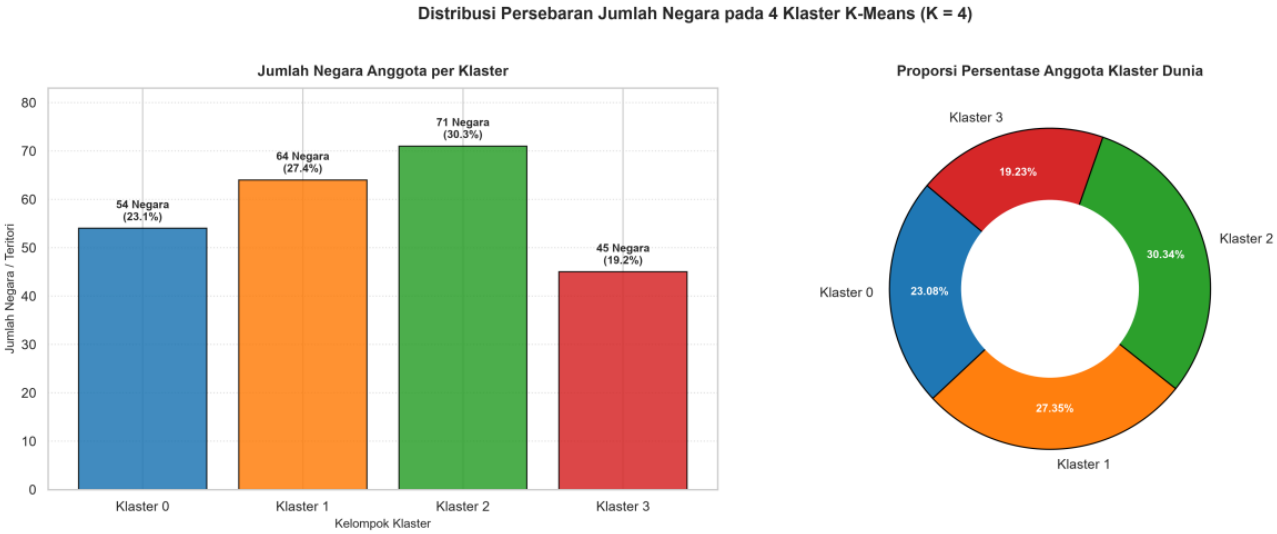
9.2 Distribusi Jumlah Negara per Klaster

Kode 9.2 menghitung frekuensi tiap klaster dengan `value_counts().sort_index()` lalu menampilkannya sebagai diagram batang (jumlah mutlak) dan donut chart (proporsi). Donut dibentuk dengan menaruh lingkaran putih di tengah diagram pai.

KODE 9.2 **Jumlah dan proporsi anggota klaster (Gambar 12)**

```
distribusi = df['Cluster'].value_counts().sort_index()          # jumlah negara per klaster
persen = distribusi / len(df) * 100
labels = [f'Klaster {i}' for i in range(K_OPTIMAL)]

fig, (ax1, ax2) = plt.subplots(nrows=1, ncols=2, figsize=(16, 6))
ax1.bar(labels, distribusi.values, color=cluster_colors, edgecolor='black')
for i, (n, p) in enumerate(zip(distribusi.values, persen.values)):
    ax1.text(i, n + 1, f'{n} Negara\n({p:.1f}%)', ha='center', fontweight='bold')
ax2.pie(distribusi.values, labels=labels, colors=cluster_colors, autopct='%1.2f%%',
        startangle=140, pctdistance=0.75, wedgeprops={'edgecolor': 'black'})
ax2.add_artist(plt.Circle((0, 0), 0.55, fc='white'))            # lubang tengah: donut chart
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'model_distribusi_klaster.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 12. Distribusi jumlah dan persentase anggota tiap klaster.

Komposisinya seimbang: Klaster 0 berisi 54 negara (23,08%), Klaster 1 sebanyak 64 (27,35%), Klaster 2 sebanyak 71 (30,34%), dan Klaster 3 sebanyak 45 (19,23%). Tidak ada klaster dominan (di atas 50%) dan tidak ada klaster kerdil (singleton).

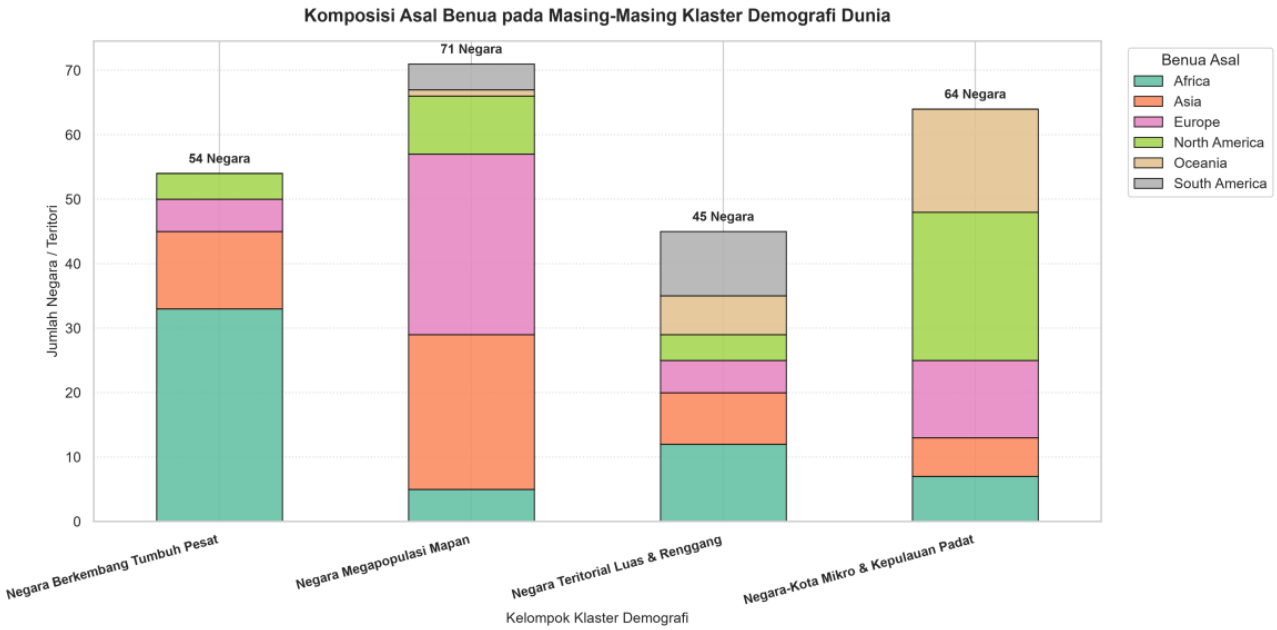
9.3 Komposisi Geografis Benua per Klaster

Tabulasi silang (`pd.crosstab`) menghitung berapa negara dari tiap benua yang jatuh ke tiap klaster; diagram batang bertumpuk memperlihatkan komposisinya. Jika klaster hanya mengulang pembagian benua, setiap batang akan didominasi satu warna.

KODE 9.3 **Tabulasi silang klaster dan benua (Gambar 13)**

```
crosstab_benua = pd.crosstab(df['Cluster_Name'], df['Continent'])     # tabel kontingensi
display(crosstab_benua)

ax = crosstab_benua.plot(kind='bar', stacked=True, colormap='Set2', edgecolor='black',
                         figsize=(14, 7))
for i, total in enumerate(crosstab_benua.sum(axis=1)):                # total anggota di atas batang
    ax.text(i, total + 1.2, f'{total} Negara', ha='center', fontweight='bold')
ax.set_xlabel('Kelompok Klaster Demografi')
ax.set_ylabel('Jumlah Negara / Teritori')
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'model_komposisi_benua_klaster.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 13. Komposisi geografis benua pada masing-masing klaster.

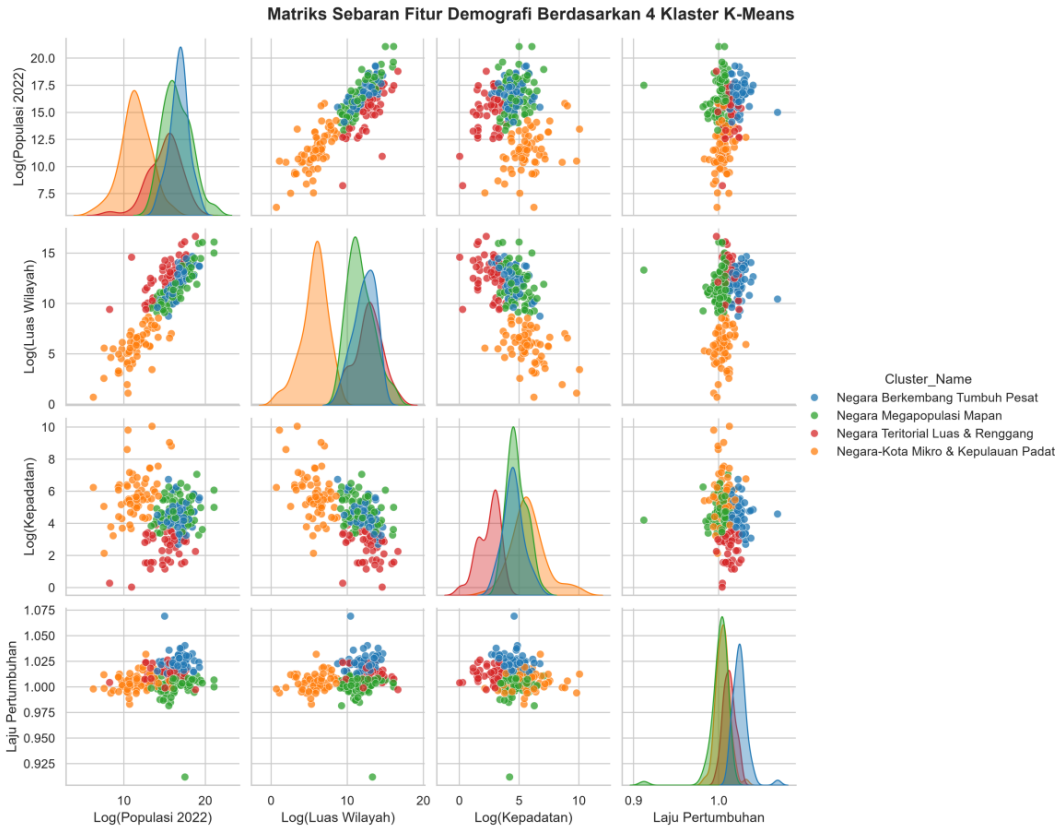
Temuan. Klaster demografi melintasi batas benua: Klaster 0 didominasi Afrika (33 negara) dan Asia (12); Klaster 1 oleh Amerika Utara/Karibia (23) dan Oseania (16); Klaster 2 oleh Eropa (28) dan Asia (24); sedangkan Klaster 3 mencakup Afrika (12), Amerika Selatan (10), dan Oseania (6). Satu benua terpecah ke beberapa klaster, dan satu klaster memuat beberapa benua, sehingga pengelompokan menurut benua memang tidak mencerminkan kesamaan tantangan demografi.

9.4 Validasi Multidimensi: Pairplot Klaster

Pairplot membuat matriks 4 × 4 dari seluruh pasangan fitur, dengan warna berbeda per klaster dan kurva KDE pada diagonal. Fitur Populasi, Luas, dan Kepadatan digambar dalam skala log agar proporsional. Jika puncak KDE antarklaster terpisah, berarti fitur tersebut memang membedakan klaster.

KODE 9.4 Pairplot sebaran fitur menurut klaster (Gambar 14)

```
custom_palette = {
    'Negara Berkembang Tumbuh Pesat':      '#1f77b4',
    'Negara-Kota Mikro & Kepulauan Padat': '#ff7f0e',
    'Negara Megapopulasi Mapan':           '#2ca02c',
    'Negara Teritorial Luas & Renggang':   '#d62728',
}
df_pairplot = pd.DataFrame({
    'Log(Populasi 2022)': df_log['Log_2022 Population'],
    'Log(Luas Wilayah)':  df_log['Log_Area (km²)'],
    'Log(Kepadatan)':     df_log['Log_Density (per km²)'],
    'Laju Pertumbuhan':   df['Growth Rate'],
    'Cluster_Name':       df['Cluster_Name'],
})
g = sns.pairplot(df_pairplot, hue='Cluster_Name', palette=custom_palette, diag_kind='kde',
                 plot_kws={'alpha': 0.75, 's': 45, 'edgecolor': 'white', 'linewidth': 0.4},
                 diag_kws={'fill': True, 'alpha': 0.4})
g.fig.suptitle('Matriks Sebaran Fitur Demografi Berdasarkan 4 Klaster K-Means', y=1.02)
g.savefig(OUTPUT_DIR / 'model_sebaran_klaster_pairplot.png', dpi=300, bbox_inches='tight')
plt.show()
```



Gambar 14. Pairplot sebaran empat klaster berdasarkan seluruh kombinasi fitur.

Temuan. Puncak distribusi antarklaster terpisah tegas pada sumbu Kepadatan, Luas Wilayah, dan Growth Rate. Klaster 1 (oranye) terisolasi pada luas sempit dan kepadatan tinggi, Klaster 0 (biru) terpisah pada pertumbuhan tinggi, dan Klaster 3 (merah) menonjol pada bentang luas berkepadatan rendah.

Dashboard komparasi sebelum dan sesudah klasterisasi

Dashboard 2 × 2 pada Kode 9.5 merangkum perubahan secara holistik: (1) pengelompokan menurut benua yang saling tumpang tindih, (2) hasil K-Means beserta centroid, (3) penurunan skewness akibat log1p, dan (4) deviasi Z-Score rata-rata tiap klaster terhadap rata-rata dunia.

KODE 9.5 Dashboard komparasi sebelum dan sesudah klasterisasi (Gambar 15)

```
palette_continent = {'Asia': '#e41a1c', 'Africa': '#377eb8', 'Europe': '#4daf4a',
                     'North America': '#984ea3', 'South America': '#ff7f00', 'Oceania': '#a65628'}
log_area = np.log1p(df['Area (km²)'])
log_dens = np.log1p(df['Density (per km²)'])
fig, axes = plt.subplots(nrows=2, ncols=2, figsize=(18, 13))

# Panel 1 dan 2: sebelum (benua) vs sesudah (klaster) pada bidang Luas-Kepadatan
sns.scatterplot(x=log_area, y=log_dens, hue=df['Continent'], palette=palette_continent,
                s=70, alpha=0.75, ax=axes[0, 0])
sns.scatterplot(x=log_area, y=log_dens, hue=df['Cluster_Name'], palette=custom_palette,
                s=70, alpha=0.8, ax=axes[0, 1])
pusat = df.assign(la=log_area, ld=log_dens).groupby('Cluster_Name')[['la', 'ld']].mean()
axes[0, 1].scatter(pusat['la'], pusat['ld'], s=250, c='red', marker='X',
                   edgecolors='black', zorder=5)                    # pusat massa tiap klaster

# Panel 3: skewness data mentah vs setelah log1p
nama = ['2022 Population', 'Area (km²)', 'Density (per km²)']
skew_mentah = [df[c].skew() for c in nama]
skew_log = [np.log1p(df[c]).skew() for c in nama]
y = np.arange(len(nama))
axes[1, 0].barh(y + 0.175, skew_mentah, 0.35, color='#d9534f', label='Data mentah')
```

```
axes[1, 0].barh(y - 0.175, skew_log, 0.35, color='#5cb85c', label='Setelah log1p')
axes[1, 0].axvspan(-0.5, 0.5, color='green', alpha=0.1)              # zona simetris
axes[1, 0].set_yticks(y)
axes[1, 0].set_yticklabels(['Populasi', 'Luas', 'Kepadatan'])
axes[1, 0].legend()

# Panel 4: deviasi Z-Score rata-rata tiap klaster (memakai X_scaled yang sudah ada)
z = pd.DataFrame(X_scaled, columns=['Populasi', 'Luas', 'Kepadatan', 'Pertumbuhan'])
z['Cluster_Name'] = df['Cluster_Name']
z.groupby('Cluster_Name').mean().T.plot(kind='bar', ax=axes[1, 1], colormap='viridis', width=0.75)
axes[1, 1].axhline(0, color='red', linestyle='--')                   # rata-rata dunia (Z = 0)
plt.tight_layout()
plt.savefig(OUTPUT_DIR / 'model_perbandingan_perubahan_klastering.png',
            dpi=300, bbox_inches='tight')
plt.show()
```

Catatan perbaikan kode

Pada notebook awal, panel 4 memanggil `scaler.fit_transform()` ulang, yang menimpa parameter scaler pelatihan dengan nama kolom berbeda. Versi di atas memakai `X_scaled` yang sudah ada, sehingga scaler yang disimpan pada Kode 8.4 tetap konsisten dengan model.



Gambar 15. Dashboard komparasi perubahan holistik sebelum dan sesudah klasterisasi.

9.5 Profiling Karakteristik Statistik Empat Klaster

Profiling menghitung rata-rata dan median tiap fitur per klaster pada satuan asli. Median melengkapi mean karena kebal terhadap pencilan. Kode 9.6 juga memilih lima negara berpopulasi terbesar di setiap klaster sebagai negara perwakilan, dan menghitung pangsa populasi dunia tiap klaster.

KODE 9.6 Profiling mean dan median, pangsa populasi, dan negara perwakilan

```
profile_mean = df.groupby('Cluster')[fitur_clustering].mean()          # rata-rata satuan asli
profile_median = df.groupby('Cluster')[fitur_clustering].median()    # median, kebal pencilan
display(profile_mean.round(4))
display(profile_median.round(4))

share = df.groupby('Cluster')['2022 Population'].sum() / df['2022 Population'].sum() * 100
print(share.round(2))                                                  # pangsa populasi dunia (%)

wakil = [df[df['Cluster'] == c].sort_values('2022 Population', ascending=False).head(5)
         for c in range(K_OPTIMAL)]                                    # top 5 populasi per klaster
df_perwakilan = pd.concat(wakil, ignore_index=True)
display(df_perwakilan[['Cluster', 'Cluster_Name', 'Country/Territory', 'Continent']
                      + fitur_clustering])
```

Indikator	Klaster 0 Tumbuh Pesat	Klaster 1 Mikro Padat	Klaster 2 Megapopulasi	Klaster 3 Luas Renggang
Jumlah anggota	54 (23,08%)	64 (27,35%)	71 (30,34%)	45 (19,23%)
Pangsa populasi dunia	24,07% (1,92 miliar)	0,35% (27,8 juta)	68,70% (5,48 miliar)	6,89% (549 juta)
Rata-rata populasi	35.535.038	435.401	77.148.016	12.203.237
Median populasi	20.211.496	96.614	11.228.821	5.185.288
Rata-rata luas (km²)	454.624	821	689.264	1.389.316
Median luas (km²)	243.704	382	88.361	342.000
Rata-rata kepadatan (jiwa/km²)	133,56	1.337,97	173,06	14,84
Laju pertumbuhan	+2,50%/tahun (1,0250)	+0,46%/tahun (1,0046)	+0,07%/tahun (1,0007)	+1,21%/tahun (1,0121)
Fokus kebijakan	Pangan, faskes ibu-anak, vokasi	Tata ruang vertikal, mitigasi air laut	Penuaan penduduk, energi mapan	Rel logistik, satelit terpencil

Membaca tabel. Selisih besar antara mean dan median di tiap klaster (misalnya populasi Klaster 2: 77,1 juta vs 11,2 juta) menunjukkan sebaran di dalam klaster masih menceng, sehingga median lebih mewakili negara "tipikal" dan mean lebih mewakili beban agregat. Klaster 2 hanya 30,34% dari jumlah negara, tetapi menampung 68,70% populasi dunia; sebaliknya Klaster 1 mencakup 27,35% negara dengan hanya 0,35% penduduk. Perbedaan inilah yang tidak tertangkap oleh pembagian benua.

9.6 Ekspor Dataset Terklaster dan Inventaris Arsip Grafik

Dataset lengkap yang telah dilengkapi kolom `Cluster` dan `Cluster_Name` diekspor ke CSV sebagai deliverable resmi, dan seluruh grafik 300 DPI di folder `output/` diinventarisasi untuk memastikan arsip visual utuh.

KODE 9.7 Ekspor CSV hasil klasterisasi dan inventaris grafik

```
path_export_csv = OUTPUT_DIR / 'world_population_clustered.csv'
df.to_csv(path_export_csv, index=False)              # index=False: tanpa kolom nomor baris
print(f'Dimensi ekspor : {df.shape[0]} baris x {df.shape[1]} kolom')       # 234 x 19
print(f'Ukuran berkas  : {path_export_csv.stat().st_size / 1024:.2f} KB')

for p in sorted(OUTPUT_DIR.glob('*.png')):           # inventaris seluruh grafik tersimpan
    print(f'{p.name:<55}{p.stat().st_size / 1024:8.1f} KB')
```

Deliverable data

Berkas `output/world_population_clustered.csv` (sekitar 36,3 KB, 234 baris × 19 kolom: 17 kolom asli ditambah *Cluster* dan *Cluster_Name*) beserta `model_kmeans.pkl` dan `scaler.pkl`.

9.7 Deployment Dashboard Web Interaktif

Hasil pemodelan diintegrasikan ke antarmuka web mandiri (`index.html`, sekitar 172 KB) yang dapat dibuka langsung di peramban tanpa server. Dashboard menyajikan:

- **Kartu KPI:** lima kartu ringkasan eksekutif (234 negara, 7,97 miliar jiwa, K = 4, reduksi skewness, artefak riset).
- **Visualisasi responsif:** donut chart, stacked bar benua, radar chart centroid, dan scatter plot 2D.
- **Simulator real-time:** pencarian negara dengan *autocomplete* untuk seluruh 234 negara, isi otomatis nilai riil, dan perhitungan jarak Euclidean ke empat centroid secara langsung.
- **Data Explorer:** tabel 234 negara dengan pencarian, filter benua, dan ekspor CSV.

Lihat hasil pengembangan

https://10040818.github.io/associate_data_scientist_world_demographic_clustering/

Pengembang: **M. IQBAL ADENAN**, Associate Data Scientist.

9.8 Kesimpulan Eksekutif dan Rekomendasi Kebijakan

Dari 234 negara dan teritori, K-Means dengan K = 4 pada empat pilar demografi (setelah eliminasi multikolinearitas, transformasi log1p, dan standardisasi Z-Score) menghasilkan empat profil yang seimbang, bermakna, dan tidak mengikuti batas benua. Seluruh 234 negara dipertahankan (Zero Data Loss). Rekomendasi kebijakan strategis per klaster:

1. **Klaster 0 (Tumbuh Pesat).** Lembaga multilateral memprioritaskan bantuan ketahanan pangan, penguatan fasilitas kesehatan dasar ibu-anak, dan investasi sekolah vokasi untuk mencegah krisis pengangguran di masa depan.
2. **Klaster 1 (Mikro Padat).** Regulasi tata ruang vertikal yang ketat, teknologi desalinasi air laut, transisi energi terbarukan lokal, dan infrastruktur proteksi kenaikan permukaan air laut.
3. **Klaster 2 (Megapopulasi).** Kerja sama strategis internasional untuk stabilitas rantai pasok energi global, mitigasi emisi karbon, dan manajemen transisi demografi penuaan penduduk.
4. **Klaster 3 (Luas Renggang).** Pemerintah setempat memprioritaskan anggaran bagi transportasi rel logistik jarak jauh, digitalisasi telekomunikasi daerah terpencil, dan pengawasan batas teritori.

Keterbatasan penelitian

Empat fitur demografi tidak mencakup faktor ekonomi, kesehatan, atau pendidikan, sehingga klaster bersifat *deskriptif demografis*, bukan peringkat kesejahteraan. Skor Silhouette sekitar 0,31 menunjukkan struktur yang layak namun dengan batas antarklaster yang tidak sangat tegas, sehingga negara di perbatasan klaster perlu ditafsirkan hati-hati. Data bersifat potret satu tahun (2022); pembaruan berkala akan menggeser posisi sebagian negara.