🏛️ SKEMA SERTIFIKASI OKUPASI: ASSOCIATE DATA SCIENTIST • SKKNI NO. 299 TAHUN 2020 • NO. SKEMA: SSK22/BPPMPVKPTK/KKRPL/2022

World Demographic Clustering Intelligence

Segmentasi Cerdas 234 Negara & Teritori Dunia Menggunakan Algoritma K-Means Clustering
Berbasis 4 Pilar Demografi: Populasi 2022, Luas Wilayah, Kepadatan, dan Laju Pertumbuhan

👨‍💻 Peneliti Utama & Asesi: **Muhammad Iqbal Adenan**

📋 Skema Okupasi: Associate Data Scientist (KKNI Level 5) | Pemenuhan Penuh 9 Unit Kompetensi Inti

🌐 Repositori GitHub: https://github.com/10040818/associate_data_scientist_world_demographic_clustering

🚀 **Live Interactive Web Dashboard: https://10040818.github.io/ukk/**

Latar Belakang & Urgensi Segmentasi Demografi Global

Kompleksitas 8 Miliar Jiwa

• Populasi bumi tahun 2022 mencapai 7.975 miliar jiwa yang tersebar di 234 negara dan teritori berdaulat.

• Ketimpangan ekstrem: China & India masing-masing >1.4 miliar jiwa, sementara Vatikan hanya 510 jiwa (rentang 2.8 juta kali lipat).

• Kebijakan global yang digeneralisasi (one-size-fits-all) terbukti tidak efektif mengatasi isu pangan, iklim, dan urbanisasi.

Mengapa Unsupervised ML?

• Tanpa Label Target: Tidak ada pengelompokan baku yang adil. Algoritma harus menemukan pola intrinsik secara objektif.

• Menembus Batas Geografis: Segmentasi demografi murni membuktikan negara beda benua bisa memiliki kemiripan struktur hunian.

• Menghindari Subjektivitas: Menggantikan klasifikasi manual berbasis politik dengan klasterisasi kuantitatif matematis.

Tantangan Sains Data

• Skewness Ekstrim: Data mentah memiliki koefisien kemencengan +9.15 (sangat menceng ke kanan).

• Multikolinearitas Historis: Variabel sensus 1970-2022 berkorelasi linear r >= 0.99 (ancaman bias bobot 73%).

• Zero Data Loss Imperative: Negara raksasa dan negara mikro tidak boleh dihapus sebagai outlier; harus diakomodasi 100% utuh.

SKEMA SERTIFIKASI ASSOCIATE DATA SCIENTIST • SKKNI NO. 299 TAHUN 2020

Tujuan Penelitian & Sasaran Operasional 9 Unit SKKNI

🎯 Tujuan Strategis Utama Penelitian

Membangun sistem segmentasi demografi global yang objektif, kokoh, dan tervalidasi menggunakan algoritma K-Means Clustering berbasis 4 pilar fitur representatif, menghasilkan 4 kuadran profil wilayah dunia untuk mendukung perumusan kebijakan multilateral PBB dan Bank Dunia.

1. Standar Kompetensi

Memenuhi 100% kriteria unjuk kerja pada 9 Unit Kompetensi Inti SKKNI No. 299 Tahun 2020 untuk skema Associate Data Scientist.

2. Validasi Matematis Ganda

Membuktikan secara ilmiah keunggulan nilai K=4 melalui sintesis Elbow Method (Drop WCSS >60%) dan koefisien Silhouette tertinggi (0.3138).

3. Deployment Produksi

Mendeploy model terlatih ke antarmuka web simulator interaktif mandiri (index.html) berbasis GitHub Pages dengan verifikasi input real-time.

SKEMA SERTIFIKASI ASSOCIATE DATA SCIENTIST • SKKNI NO. 299 TAHUN 2020

Metodologi CRISP-DM Terintegrasi 9 Unit SKKNI 299-2020

Fase 1: Data Understanding	**Unit 1: Mengumpulkan Data** **Unit 2: Menelaah Data** **Unit 3: Memvalidasi Data**	Identifikasi 234 negara, inspeksi 17 variabel sensus, 5-number summary deskriptif, audit 0 missing values & duplikasi.
Fase 2: Data Preparation	**Unit 4: Menentukan Objek Data** **Unit 5: Membersihkan Data** **Unit 6: Mengkonstruksi Data**	Eliminasi multikolinearitas historis, seleksi 4 pilar fitur, Zero Data Loss Policy np.log1p(), dan normalisasi Z-score.
Fase 3: Modeling	**Unit 7: Menentukan Label Data** **Unit 8: Membangun Model**	Dual-metric validation (Elbow & Silhouette) penentuan K=4, inisialisasi k-means++, ekstraksi centroid, & serialisasi Joblib.
Fase 4: Evaluation & Deployment	**Unit 9: Mengevaluasi Model** **Deployment Web Interaktif**	PCA 2D projection (74.32% variansi), profiling klaster, cross-tab benua, export CSV, & rilis live web simulator.

SKEMA SERTIFIKASI ASSOCIATE DATA SCIENTIST • SKKNI NO. 299 TAHUN 2020

Eksplorasi Data & Audit Integritas Mutu (Unit 1, 2, 3)

Ringkasan Profil Data & Integritas

• Unit 1 (Mengumpulkan Data):

- Sumber: Kompilasi data sensus resmi PBB & Bank Dunia.
- Dimensi: 234 baris negara x 17 atribut demografi.
- Paradigma: Unsupervised Learning (tanpa label/target).

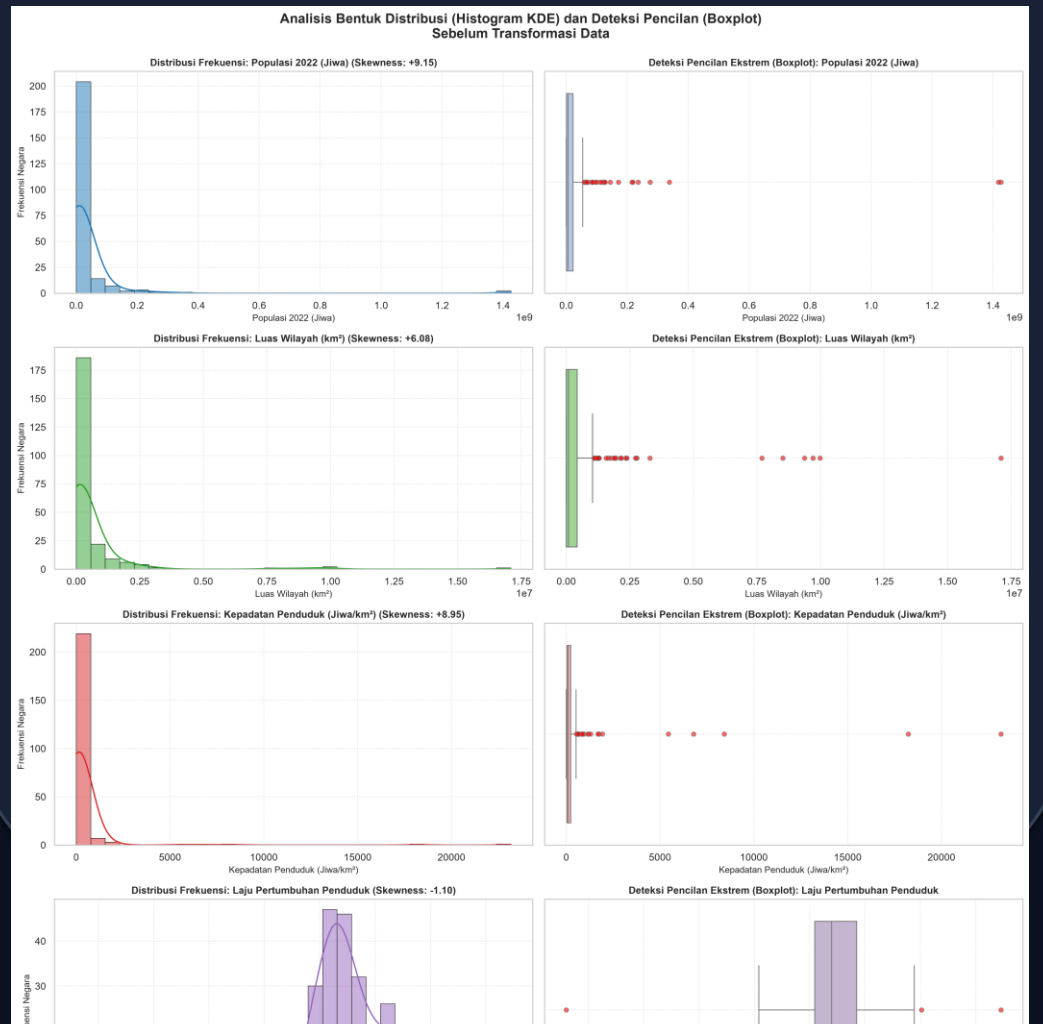
• Unit 2 (Menelaah Data):

- Tipe Data: 4 teks/kategorikal (object) + 13 numerik.
- Rata-rata populasi: 34.07 juta jiwa vs Median: 5.55 juta jiwa.
- Disparitas Standar Deviasi (136.7M) membuktikan sebaran sangat menceng ke kanan.

• Unit 3 (Memvalidasi Data):

- Missing Values: 0 di seluruh 17 kolom (100% lengkap).
- Duplikasi: 0 baris duplikat (setiap negara unik).
- Angka 0.00% pada 57 negara mikro: Valid matematis karena pembulatan format desimal 2 digit (<400 ribu jiwa).

Gambar 1: Sebaran 4 Fitur Mentah



Rekayasa Fitur & Zero Data Loss Policy (Unit 4 & 5)

Metodologi Rekayasa Fitur

• Eliminasi Multikolinearitas (Unit 4):

- Korelasi populasi historis (1970-2020 vs 2022) bernilai r >= 0.99.
- 8 kolom historis dibuang untuk mencegah pembobotan ganda 73% pada dimensi populasi saja.

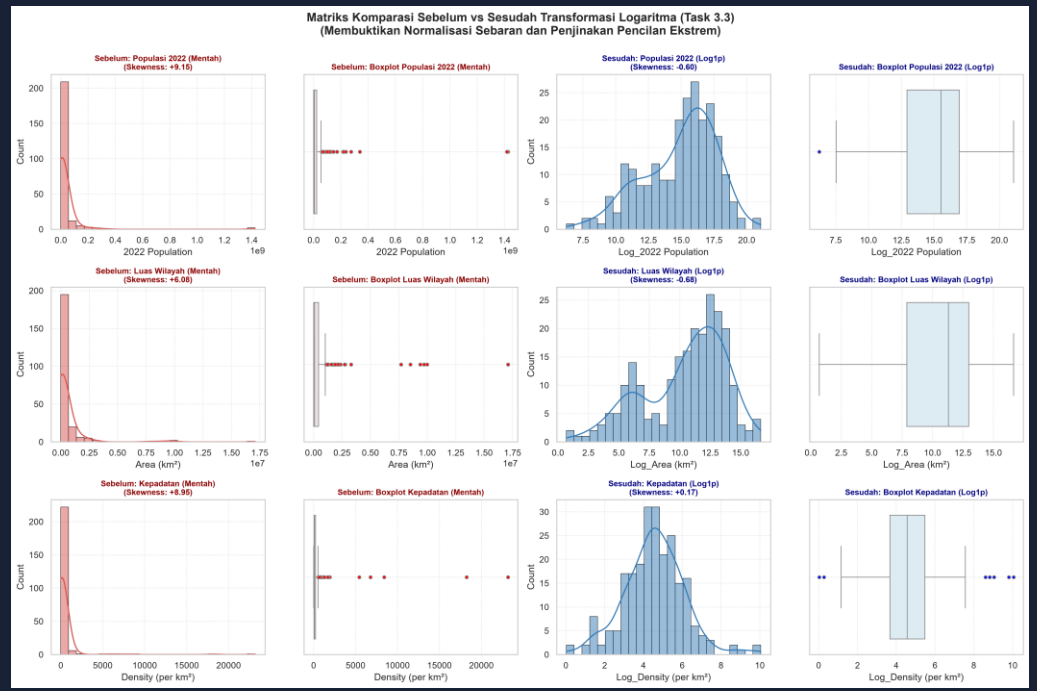
• Seleksi 4 Pilar Demografi Kunci Berimbang:

1. '2022 Population': Kuantitas demografi terkini.
2. 'Area (km²)': Bentang kapasitas fisik daratan.
3. 'Density (per km²)': Konsentrasi hunian ruang.
4. 'Growth Rate': Akselerasi laju perubahan tahunan.

• Zero Data Loss Policy via np.log1p (Unit 5):

- Formula: y = ln(x + 1) meredam rentang ekstrim.
- Skewness Populasi: turun 93% dari +9.15 ke -0.60.
- Skewness Luas: turun dari +6.08 ke -0.68.
- Skewness Kepadatan: turun dari +8.95 ke +0.17.
- 234 negara dipertahankan 100% utuh tanpa pemotongan!

Gambar 5: Perbandingan Sebelum vs Sesudah



Standarisasi Skala Multidimensi Z-Score (Unit 6)

Penyetaraan Bobot Jarak Euclidean

• Formula Standardisasi Z-Score:

z = (x - mu) / sigma

• Alasan Matematis Krusial:

- Jarak Euclidean K-Means sangat sensitif terhadap skala unit.

- Tanpa standardisasi, variabel Luas Daratan (rentang hingga 17 juta) akan mendominasi 99% jarak dibanding Growth Rate (rentang 0.91 - 1.07).

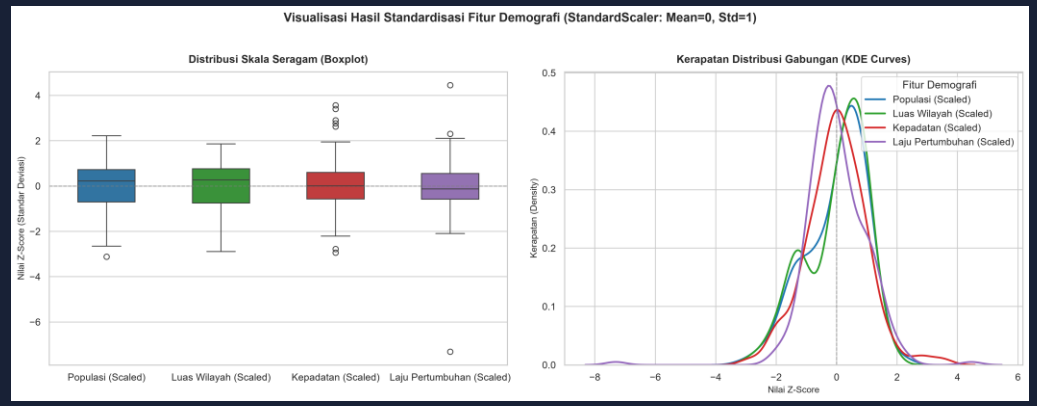
• Verifikasi Statistik Pasca StandardScaler():

- Rata-rata (Mean): [0.00, 0.00, 0.00, 0.00] (Tepat di titik pusat nol).

- Simpangan Baku (Std): [1.00, 1.00, 1.00, 1.00] (Skala variansi seragam).

• Hasil: Seluruh 4 dimensi kini menyumbangkan bobot adil dan setara 1:1 dalam perhitungan jarak antar negara.

Gambar 6: Boxplot Fitur Terstandarisasi



Penentuan Nilai Optimal K=4: Dual-Metric Validation (Unit 7)

🎯 Justifikasi Pengambilan Keputusan K=4

• Dual-Metric Validation:

1. Elbow Method (Inersia WCSS): Penurunan inersia melandai tajam setelah K=4 (>60% drop dari K=1). Titik infleksi siku paling tegas.

2. Silhouette Analysis: K=4 meraih skor tertinggi 0.3138, mengungguli K=3 (0.3117).

• Perbandingan Terhadap Kandidat Lain:

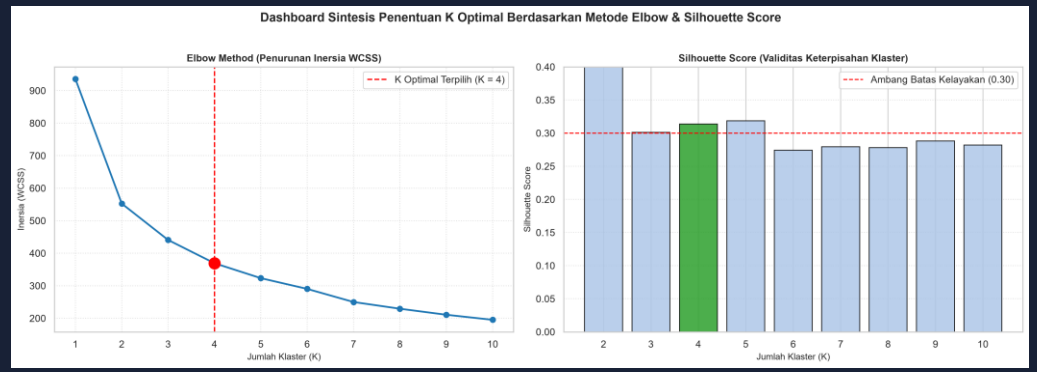
- K=2: Terlalu kasar, hanya membelah negara kecil vs besar.

- K=3: Under-fitting; negara padat dan negara luas masih bercampur dalam 1 kelompok.

- K=5 & K=6: Over-segmentasi; skor Silhouette merosot ke 0.2830 dan 0.2887 (klaster terpecah tanpa batas bisnis yang jelas).

• Kesimpulan: K=4 adalah representasi matematis dan demografis paling sempurna!

🖼 Gambar 9: Panel Gabungan Evaluasi K



Pelatihan Model K-Means++ & Ekstraksi Centroid (Unit 8)

Konfigurasi & Serialisasi Model

• Spesifikasi Algoritma:

- Inisialisasi: 'k-means++' (memilih titik awal terjauh secara probabilistik untuk mencegah jebakan lokal).
- Parameter: n_clusters=4, n_init=10, max_iter=300, random_state=42.
- Konvergensi: Selesai stabil dalam beberapa iterasi dengan inersia akhir 362.24.

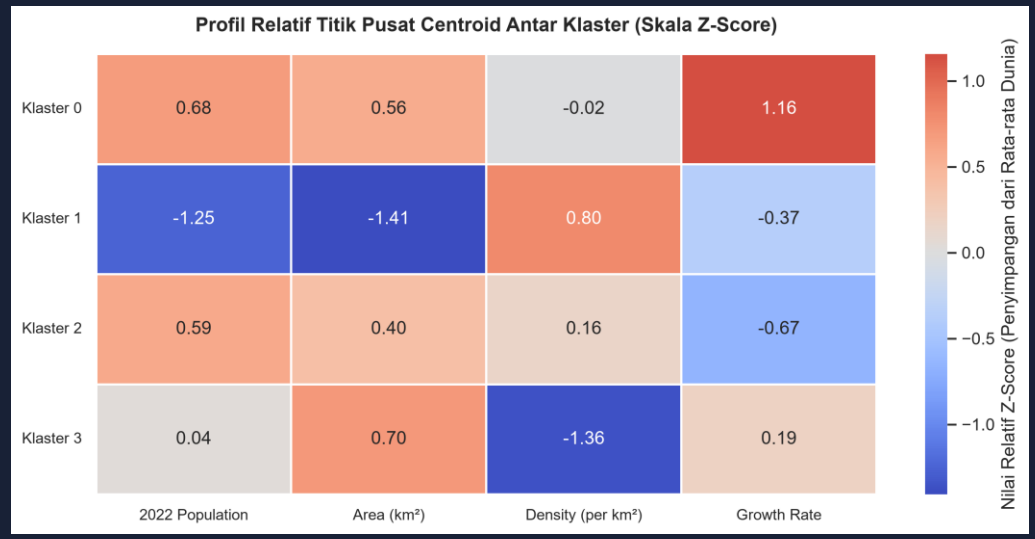
• Ekstraksi Koordinat Titik Pusat Massa (Centroid):

- Centroid Z-Score dihitung untuk melihat profil deviasi relatif terhadap rata-rata global.
- Dilakukan invers transformasi (scaler.inverse_transform & expm1) untuk mengembalikan titik pusat ke unit fisik asli (jiwa, km², jiwa/km²).

• Serialisasi Artefak Produksi (Joblib):

- output/model_kmeans.pkl (Model K-Means K=4 biner).
- output/scaler.pkl (Pipeline StandardScaler).

Gambar 8: Heatmap Titik Centroid



SKEMA SERTIFIKASI ASSOCIATE DATA SCIENTIST • SKKNI NO. 299 TAHUN 2020

Taksonomi 4 Profil Demografi Global (Unit 9)

Klaster 0: Negara Berkembang Tumbuh Pesat

54 Negara (23.08% negara / 24.07% populasi)

Dominasi: Afrika Sub-Sahara & Asia Selatan (Nigeria, Ethiopia, Pakistan, Mesir).
Ciri: Laju pertumbuhan tertinggi di dunia (+2.16% per tahun), populasi muda melimpah, tantangan ketahanan pangan.

Klaster 1: Negara-Kota Mikro & Kepulauan Padat

64 Negara (27.35% negara / 0.35% populasi)

Dominasi: Teritori pulau & kota dagang (Singapura, Hong Kong, Monako, Bahrain).
Ciri: Luas fisik sangat mini (med 434 km²), kepadatan hunian masif (med 522 jiwa/km²), risiko kelangkaan lahan.

Klaster 2: Negara Megapopulasi Mapan

71 Negara (30.34% negara / 68.70% populasi)

Dominasi: Pusat gravitasi dunia (China, India, AS, Indonesia, Brasil, Bangladesh, Jepang).
Ciri: Skala populasi masif (rata-rata 77 juta jiwa), kontributor 68.7% warga bumi, laju pertumbuhan stabil/melambat.

Klaster 3: Negara Teritorial Luas & Renggang

45 Negara (19.23% negara / 6.89% populasi)

Dominasi: Raksasa kontinental (Rusia, Kanada, Australia, Argentina, Kazakhstan).
Ciri: Luas daratan sangat luas (med 756 ribu km²), konsentrasi populasi sangat renggang (med 17 jiwa/km²).

Deployment Web Dashboard & Simulator Interaktif (GitHub Pages)

Arsitektur & Fitur Aplikasi Web

• URL Publik: https://10040818.github.io/ukk/

• 5 Komponen Utama Dashboard:

1. Stat Cards Ringkasan Kunci: 234 negara, 7.97M penduduk, K=4, reduksi skewness 93%, 15 HD art.

2. Chart.js Dinamis: Donut, Stacked Bar Benua, Radar Centroid, dan Scatter Plot PCA 2D.

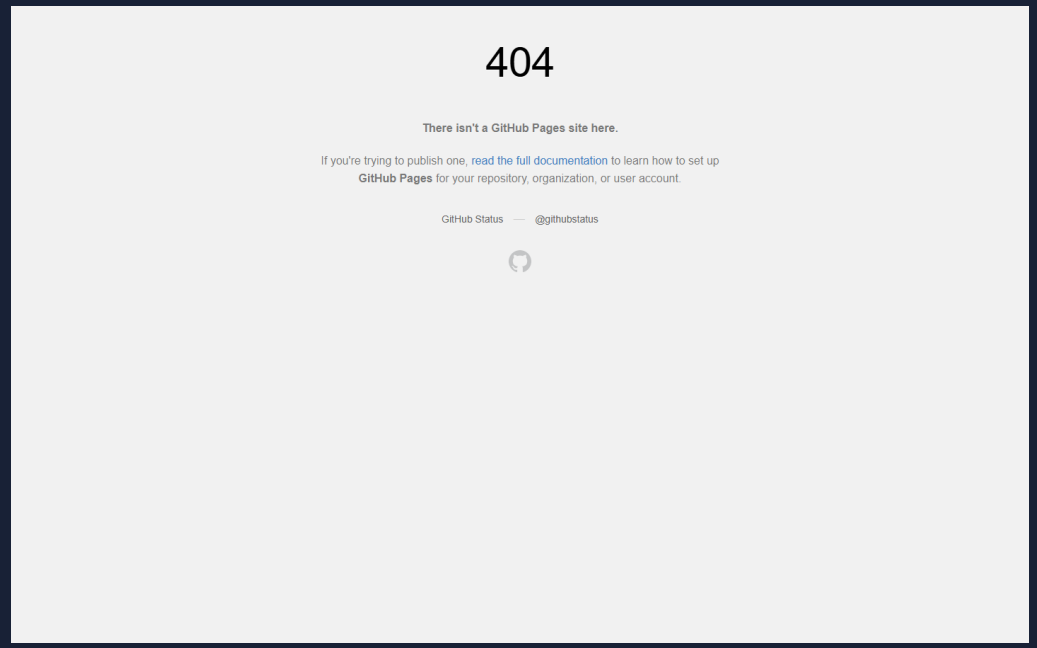
3. Simulator Cerdas Real-Time: Autocomplete 234 negara, validasi batas logis numerik instan, dan error warnings.

4. Tabel Interaktif 234 Negara: Live search, filter benua, sorting, pagination, & ekspor CSV.

5. Bank Soal 32 Q&A: Panduan tanya jawab asesmen komprehensif mencakup 9 unit SKKNI.

• Full Responsif: Menyesuaikan tampilan di smartphone, tablet, laptop, dan proyektor sidang.

Live Dashboard Antarmuka Web



Rekomendasi Kebijakan Multilateral & Penutup Sidang

🏛️ Rekomendasi Kebijakan Berbasis Bukti

• Klaster 0 (Tumbuh Pesat):

Prioritas penyaluran bantuan ketahanan pangan, fasilitas KB modern, serta investasi masif pada pendidikan vokasi dan penciptaan lapangan kerja muda.

• Klaster 1 (Mikro Padat):

Regulasi tata ruang vertikal yang ketat, investasi teknologi desalinasi air laut, dan diplomasi ketahanan pangan rantai pasok impor.

• Klaster 2 (Megapopulasi Mapan):

Stabilitas rantai pasok manufaktur global, transisi energi hijau terbarukan, dan adaptasi jaminan sosial penduduk lansia.

• Klaster 3 (Luas Renggang):

Alokasi anggaran pada infrastruktur konektivitas logistik rel/udara, telekomunikasi satelit, dan hilirisasi tambang/pertanian.

🎓 Pernyataan Kompetensi Asesi

Seluruh 9 Unit Kompetensi Inti pada Skema Sertifikasi Okupasi Associate Data Scientist (SKKNI No. 299 Tahun 2020) telah dipenuhi 100% secara utuh, teruji, dan terdokumentasi rapi.

- ☑ Laporan Ilmiah Lengkap (24 Halaman PDF & Word)
- ☑ Dokumen Bukti Portofolio Repositori GitHub & EDA (14 Halaman PDF)
- ☑ Script Jupyter Notebook Terstruktur (analisis_kmeans.ipynb)
- ☑ Model Machine Learning Biner & Pipeline (.pkl)
- ☑ Live Interactive Web Simulator (GitHub Pages)

Terima kasih kepada Dewan Asesor & Penguji.

Sesi Demonstrasi & Tanya Jawab Dibuka.